Critères d'identification

hypothèse : l'ensemble des N paires d'échantillons entrée-sortie est disponible :

$$\{u(k), y(k)\}_{1 \leq k \leq N}$$

N est suffisamment grand.

Principal critère considéré dans ce cours :

principal critère considéré *

1) Minimisation d'une norme sur les erreurs de prédiction : $\varepsilon(k|k-1,\theta)$

2) Blanchiment de l'erreur de prédiction : on introduit des variables auxiliaires appelées variables instrumentales permettant de décorreler le bruit affectant le modèle du vecteur des observations.

1) Minimisation d'une norme sur les erreurs de prédiction (E.P.)

$$\varepsilon(k|k-1,\theta) = \underbrace{y(k)}_{\substack{\text{échantillon} \\ \text{prélevé en sortie} \\ \text{du processus}}} - \underbrace{\hat{y}(k|k-1,\theta)}_{\substack{\text{sortie du} \\ \text{prédicteur}}}$$

On définit $J_N(\theta) := \| \mathcal{E}_N(\theta) \|_2^2$ (1)

où $\mathcal{E}_N(\theta) = \begin{bmatrix} \varepsilon(1|0,\theta) \\ \varepsilon(2|1,\theta) \\ \vdots \\ \varepsilon(N|N-1,\theta) \end{bmatrix} \in \mathbb{R}^N$, et $\| \cdot \|_2$ correspond à la norme euclidienne.

Remarque : On peut considérer n'importe quelle autre norme.

Par exemple : $\| \mathcal{E}_N(\theta) \|_1 = \sum_{k=1}^{N} | \varepsilon(k|k-1,\theta) |$; $\| \mathcal{E}_N(\theta) \|_\infty = \max_{1 \le k \le N} | \varepsilon(k|k-1,\theta) |$

$$\| \mathcal{E}_N(\theta) \|_p = \left(\sum_{k=1}^{N} | \varepsilon(k|k-1,\theta) |^p \right)^{1/p} \qquad p = 1, 2, \ldots \in \mathbb{N}$$

Le problème d'identification consiste alors à résoudre le problème d'optimisation

$$\hat{\theta} = \arg \min_{\theta \in \mathbb{R}^n} J_N(\theta) \quad (2)$$

$\hat{\theta}$ est le vecteur des paramètres qui minimise (globalement) le critère $J_N(\theta)$.

→ Recherche du minimum GLOBAL

Remarque : Le critère dit "des moindres carrés" n'est rien d'autre que

$$\tilde{J}_N(\theta) := \frac{1}{N} J_N(\theta) = \frac{1}{N} \sum_{k=1}^{N} \varepsilon(k|k-1,\theta)^2$$

Lorsque le critère à minimiser est quadratique en θ, le problème d'optimisation (2) possède un minimum UNIQUE, qui est le minimum GLOBAL, et peut s'écrire ANALYTIQUEMENT, càd par le biais d'une expression explicite de $\hat{\theta}$ en fonction des $u(k)$, $y(k)$ $k = 1$ à N.

C'est le cas pour des structures de modèle bruité pour lesquelles l'erreur de prédiction s'écrit linéairement en les paramètres (structures ARX, FIR)

Ce n'est plus vrai si l'E.P. est non-linéaire en les paramètres, ou bien si le vecteur des paramètres θ est contraint par des relations algébriques, des inégalités ...

Auquel cas, le problème d'identification devient $\hat{\theta} = \arg \underset{\theta \in \mathcal{D} \subset \mathbb{R}^{n_\theta}}{\text{Min}} \; \mathcal{V}_N(\theta)$ (3)

où $\mathcal{D}$ représente le domaine paramétrique admissible.

Pour un tel problème, on a recours à des algorithmes d'optimisation dont la présentation exhaustive sort du cadre de ce cours.

Application à la structure ARX

$$\varepsilon(k|k-1,\theta) = y(k) - \hat{y}(k|k-1,\theta), \quad \text{où } \hat{y}(k|k-1,\theta) = \theta^T \varphi(k-1)$$

avec $\theta = \begin{bmatrix} a_1 \\ \vdots \\ a_{n_A} \\ b_1 \\ \vdots \\ b_{n_B} \end{bmatrix}$ et $\varphi(k-1) = \begin{bmatrix} -y(k-1) \\ \vdots \\ -y(k-n_A) \\ u(k-d-1) \\ \vdots \\ u(k-d-n_B) \end{bmatrix}$, on considère ici que n_A, n_B et d sont fixés.

(n_A, n_B et d : complexité du modèle ARX.)

$\theta, \varphi(k-1) \in \mathbb{R}^{n_A+n_B}$.

Théorème : La solution du problème d'optimisation (1), pour le cas de la structure ARX, est donnée par :

$$\hat{\theta}(N) = \left(\Phi(N)\Phi(N)^T\right)^{-1}\Phi(N)Y(N) \qquad (4)$$

où $\Phi(N) = [\varphi(0)\ \varphi(1) \cdots \varphi(N-1)] \in \mathbb{R}^{(n_A+n_B)\times N}$ et $Y(N) = \begin{bmatrix} y(1) \\ \vdots \\ y(N) \end{bmatrix} \in \mathbb{R}^N$

sous réserve que la matrice carrée $\Phi(N)\Phi(N)^T$ soit inversible.

Preuve : Posons $\hat{Y}(N,\theta) = \begin{bmatrix} \hat{y}(1|0,\theta) \\ \vdots \\ \hat{y}(N|N-1,\theta) \end{bmatrix} \in \mathbb{R}^N$. Pour la structure ARX, on a

$\hat{y}(k|k-1,\theta) = \theta^T \varphi(k-1) = \varphi(k-1)^T\theta$. Ainsi, $\hat{Y}(N,\theta) = \begin{bmatrix} \varphi(0)^T\theta \\ \varphi(1)^T\theta \\ \vdots \\ \varphi(N-1)^T\theta \end{bmatrix} = \begin{bmatrix} \varphi(0)^T \\ \varphi(1)^T \\ \vdots \\ \varphi(N-1)^T \end{bmatrix} \theta$.

Soit $\hat{Y}(N,\theta) = \Phi(N)^T\theta$. Le critère s'écrit donc :

$$J_N(\theta) = \left(Y(N) - \hat{Y}(N,\theta)\right)^T \left(Y(N) - \hat{Y}(N,\theta)\right)$$

$$= Y(N)Y(N)^T - 2\theta^T\Phi(N)Y(N) + \theta^T\Phi(N)\Phi(N)^T\theta.$$

$\hat{\theta}(N)$ est un minimum du critère lorsque la Condition Nécessaire d'optimalité est satisfaite, à savoir, lorsque

$$\nabla_\theta J_N(\theta)\Big|_{\theta=\hat{\theta}(N)} = 0 \qquad (5)$$

$\nabla_\theta J_N(\theta)$: vecteur gradient du critère $J_N(\theta)$ suivant θ

↳ $\in \mathbb{R}^{n_A+n_B}$ pour l'ARX.

Rappel : formes quadratiques et formule vectorielle du vecteur gradient.

Soient $A \in \mathbb{R}^{n\times n}$ avec $A = A^T$, $b \in \mathbb{R}^n$ et $c \in \mathbb{R}$. On définit la forme quadratique $f(x) := x^T A x + b^T x + c$, $\forall x \in \mathbb{R}^n$.

$\nabla_x f(x) = 2Ax + b \in \mathbb{R}^n$. Pour $x = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}$, $\nabla_x f(x) = \begin{bmatrix} \frac{\partial f(x)}{\partial x_1} \\ \vdots \\ \frac{\partial f(x)}{\partial x_n} \end{bmatrix}$.

La matrice hessienne de $f(x)$, notée $H_x f(x)$ correspond à :

$$H_x f(x) = \nabla_x \nabla_x f(x) = \begin{bmatrix} \nabla_x \frac{\partial f(x)}{\partial x_1}^T \\ \vdots \\ \nabla_x \frac{\partial f(x)}{\partial x_n}^T \end{bmatrix} = \begin{bmatrix} \frac{\partial^2 f(x)}{\partial x_1^2} & \frac{\partial^2 f(x)}{\partial x_1 \partial x_1} & \cdots & \frac{\partial^2 f(x)}{\partial x_n \partial x_1} \\ \frac{\partial^2 f(x)}{\partial x_2 \partial x_1} & \frac{\partial^2 f(x)}{\partial x_2^2} & & \vdots \\ \vdots & & \ddots & \\ \frac{\partial^2 f(x)}{\partial x_n \partial x_1} & \cdots & & \frac{\partial^2 f(x)}{\partial x_n^2} \end{bmatrix} \in \mathbb{R}^{n\times n}$$

matrice carrée

Pour f continument différentiable à l'ordre 2, le Théorème de Schwarz précise que $\frac{\partial^2 f(x)}{\partial x_i \partial x_j} = \frac{\partial^2 f(x)}{\partial x_j \partial x_i}$ (permutation de l'ordre des dérivées partielles)

$\Longrightarrow$ $H_x f(x)$ est une matrice symétrique.

Ainsi, on a $\nabla_\theta J_N(\theta) = 2\,\Phi(N)\Phi(N)^T\theta - 2\,\Phi(N)Y(N)$

$= 2\left(\Phi(N)\Phi(N)^T\theta - \Phi(N)Y(N)\right).$

$\nabla_\theta J_N(\theta)\Big|_{\theta=\hat\theta(N)} = 0 \iff \Phi(N)\Phi(N)^T\hat\theta(N) - \Phi(N)Y(N) = 0$, ce qui conduit au résultat (4), sous réserve que $\Phi(N)\Phi(N)^T \in \mathbb{R}^{\tilde n \times \tilde n}$ soit inversible, $\tilde n = n_A + n_B$.

La condition nécessaire et suffisante d'optimalité garantit que $\hat\theta(N)$ minimise le critère (1) si, et seulement si $H_\theta J_N(\theta)\Big|_{\theta=\hat\theta(N)} > 0$ (6) matrice définie positive.

Ici, $H_\theta J_N(\theta) = 2\,\Phi(N)\Phi(N)^T$ qui est une matrice symétrique par construction.

Condition Nécessaire pour que (6) soit vérifiée : $\boxed{N \geq n_A + n_B}$ (7)

Condition Nécessaire ET Suffisante pour que (6) soit vérifiée :

Le signal d'entrée $u(k)$ est d'excitation persistante d'ordre au moins égal à $n_A + n_B$.

Notion d'excitation persistante

Un signal $\{u(k)\}_{k=0 \text{ à } N-1}$ est dit d'excitation persistante d'ordre $n \in \mathbb{N}^*$ si :

i) la limite suivante existe $\bar{c}_{uu}(j) := \lim_{N\to\infty} \frac{1}{N} \sum_{k=0}^{N-1} u(k+j)\,u(k)$

ii) la matrice $n \times n$ suivante est inversible et définie positive :

$$\bar{C}_{uu}(n) := \begin{bmatrix} \bar{c}_{uu}(0) & \bar{c}_{uu}(1) & \cdots & \bar{c}_{uu}(n-1) \\ \bar{c}_{uu}(-1) & \bar{c}_{uu}(0) & \cdots & \bar{c}_{uu}(n-2) \\ \vdots & \vdots & \ddots & \vdots \\ \bar{c}_{uu}(-n+1) & \bar{c}_{uu}(-n+2) & \cdots & \bar{c}_{uu}(0) \end{bmatrix}.$$

Remarque : Si $\{u(k)\}$ est une suite de variables aléatoires stationnaire et ergodique alors $\lim_{N\to\infty} \frac{1}{N} \sum_{k=0}^{N-1} u(k+j)\,u(k) = \underbrace{E\left(u(k+j)\,u(k)\right)}_{\text{espérance mathématique}} =: c_{uu}(j)$

où $c_{uu}(j)$ est la fonction d'autocorrélation de u.

Dans ce cas $\bar{C}_{uu}(n)$ est égale à la matrice d'autocorrélation.

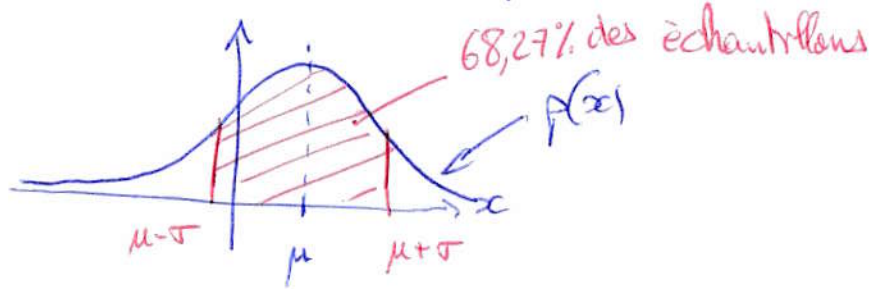
Exemples de signaux d'excitation persistante :

i) Une suite de variables aléatoires (VA), indépendantes et identiquement distribuée (iid) de moyenne nulle et de variance $\lambda = \sigma^2$ (σ écart-type) possède une matrice d'autocorrelation égale à $\lambda \mathbb{1}_n = \sigma^2 \mathbb{1}_n = \begin{bmatrix} \sigma^2 & & \\ & \ddots & \\ & & \sigma^2 \end{bmatrix} > 0$ pour tout $n \in \mathbb{N}^*$ $\longrightarrow$ d'excitation persistante d'ordre n quelconque.

Le bruit blanc gaussien (BBG) de moyenne $\mu = 0$ et de variance $\lambda = \sigma^2$, noté $\mathcal{N}(\mu, \sigma^2)^*$ est d'excitation persistante d'ordre quelconque.

Rappel : la densité de probabilité d'une telle loi d'écart $p(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$.

histogramme



* pour faire référence à la loi normale

$\longrightarrow$ fonction Matlab® >> randn(p, m)

pour générer une matrice à p lignes et m colonnes de valeurs aléatoires qui suivent la loi normale. (moyenne nulle, variance = 1).

ii) La n-multisine est le signal défini par :

$$u(k) = \left(\sum_{i=1}^{n} \cos(2\pi \nu_i + \varphi_i) \right) \times U_0$$

où $U_0 > 0$ est l'amplitude,

$0 \leq \nu_1 < \nu_2 < \dots < \nu_n \leq \frac{f_e}{2}$ (fréquence de Nyquist),

$\varphi_i \in [-\pi, \pi[\quad \forall i \in 1 \text{ à } n$,

C'est un signal d'excitation persistante d'ordre $\begin{cases} 2n & \text{si } 0 < \nu_1 \text{ et } \nu_n < \frac{f_e}{2} \\ 2n-1 & \text{si } 0 = \nu_1 \text{ ou } \nu_n = \frac{f_e}{2} \\ 2n-2 & \text{si } 0 = \nu_1 \text{ ET } \nu_n = \frac{f_e}{2} \end{cases}$

iii) La Séquence Binaire Pseudo-Aléatoire (SBPA) de période maximale $M \in \mathbb{N}^*$ est d'excitation persistante d'ordre $M-1$.

(Voir notes manuscrites sur la SBPA).

En anglais : Pseudo Random Binary Sequence (PRBS).

Etant donné un signal $u(k)$, d'excitation persistante d'ordre n.

Soit $U(f) := \sum_{k=0}^{+\infty} u(k)\, e^{-j\omega T_e k}$ sa transformée de Fourier discrète,

où $\omega = 2\pi f$ et f la fréquence considérée pour U.

Lorsque $u(k)$ est périodique (de période T_0), le module du spectre : $|U(f)|$ ne contient que n raies d'amplitude non négligeable.

Un signal d'excitation persistante appliqué à l'entrée d'un processus à identifier doit pouvoir solliciter tous les modes du système recherchés, dans la bande de fréquence $\left[0, \frac{1}{2T_e}\right[$.

Application à la structure ARMAX

$$\varepsilon(k|k-1,\theta) = -\frac{q^{-d}B(q^{-1},\theta)}{C(q^{-1},\theta)}u(k) + \frac{A(q^{-1},\theta)}{C(q^{-1},\theta)}y(k)$$

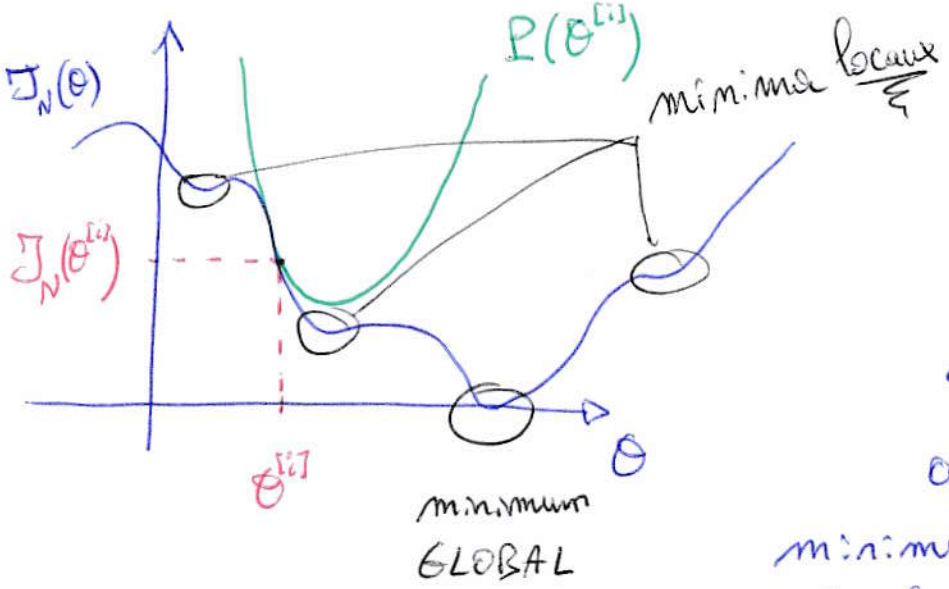
où
$$\begin{cases} A(q^{-1},\theta) = 1 + a_1 q^{-1} + \dots + a_{n_A} q^{-n_A} \\ B(q^{-1},\theta) = b_1 q^{-1} + \dots + b_{n_B} q^{-n_B} \\ C(q^{-1},\theta) = 1 + c_1 q^{-1} + \dots + c_{n_C} q^{-n_C} \end{cases},$$

$$\theta^T = [a_1 \dots a_{n_A}\ b_1 \dots b_{n_B}\ c_1 \dots c_{n_C}],\ \theta \in \mathbb{R}^{n_A+n_B+n_C}$$

On suppose la complexité du modèle fixée (n_A, n_B, n_C) ainsi que le retard pur d.

$J_N(\theta) = \|\varepsilon_N(\theta)\|_2^2$ n'est pas quadratique en θ

$\Longrightarrow$ pas d'expression explicite de $\hat{\theta}(N)$ comme pour l'ARX.



pour $\theta^{[i]}$ (à l'itération i) donné, on approche le critère $J_N(\theta^{[i]})$ par la forme quadratique $P_N(\theta^{[i]})$, issue d'un développement de Taylor de $J_N(\theta)$ à l'ordre 2, au voisinage de $\theta^{[i]}$, dont on détermine le minimum, $\theta^{[i+1]}$ et on recommence l'approximation en boucle jusqu'à convergence.

On pose (développement de Taylor) :

$$P_N^{[i]}(\theta) := J_N(\theta^{[i]}) + (\theta-\theta^{[i]})^T \nabla_\theta J_N(\theta)\Big|_{\theta=\theta^{[i]}} + \frac{1}{2}(\theta-\theta^{[i]})^T H_\theta J_N(\theta)\Big|_{\theta=\theta^{[i]}} (\theta-\theta^{[i]}) \quad (8)$$

Remarque : $P_N^{[i]}(\theta^{[i]}) = J_N(\theta^{[i]})$ et $P_N^{[i]}(\theta) \approx J_N(\theta)$ au voisinage de $\theta^{[i]}$.

Le minimum de $P_N^{[i]}(\theta)$ est donné par :

$$\theta^{[i+1]} = \theta^{[i]} - \left(H_\theta J_N(\theta)\Big|_{\theta=\theta^{[i]}}\right)^{-1} \nabla_\theta J_N(\theta)\Big|_{\theta=\theta^{[i]}} \quad (9)$$

↳ relation itérative à incrémenter tant qu'un critère d'arrêt (de l'itération) n'est pas vérifié :

exemple tant que $J_N(\theta^{[i]}) \geq$ Valeur choisi par l'utilisateur.

La relation (9) nécessite le calcul, à chaque itération,

* du vecteur gradient $\nabla_\theta J_N(\theta) \in \mathbb{R}^{n_A+n_B+n_C}$
* de la matrice Hessienne $H_\theta J_N(\theta) \in \mathbb{R}^{\hat{n}\times\hat{n}}$, $\hat{n} = n_A+n_B+n_C$.

Cet algorithme est connu sous le nom d'Algorithme de Newton.

↳ Aucune garantie de convergence vers le minimum GLOBAL.

↳ se décline en | Algorithme du Gradient
| Algorithme de quasi Newton.

$$\nabla_\theta J_N(\theta) = \nabla_\theta \sum_{k=1}^{N} \varepsilon(k|k-1,\theta)^2 = 2\sum_{k=1}^{N} \varepsilon(k|k-1,\theta)\nabla_\theta \varepsilon(k|k-1,\theta)$$

$$H_\theta J_N(\theta) = \nabla_\theta \nabla_\theta J_N(\theta) = \underbrace{2\sum_{k=1}^{N} \nabla_\theta \varepsilon(k|k-1,\theta)\nabla_\theta \varepsilon(k|k-1,\theta)^T}_{\text{terme défini positif}} + \underbrace{2\sum_{k=1}^{N} \varepsilon(k|k-1,\theta) H_\theta \varepsilon(k|k-1,\theta)}_{\begin{array}{l}\text{terme pris en compte dans Algo. Newton}\\ \text{ignoré pour algo. quasi-Newton}\end{array}}$$

Calcul de $\nabla_\theta \varepsilon(k|k-1,\theta)$:

$$\nabla_\theta \varepsilon(k|k-1,\theta) = \begin{bmatrix} \partial_{a_1} \varepsilon(k|k-1,\theta) \\ \vdots \\ \partial_{a_{n_A}} \varepsilon(k|k-1,\theta) \\ \partial_{b_1} \varepsilon(k|k-1,\theta) \\ \vdots \\ \partial_{b_{n_B}} \varepsilon(k|k-1,\theta) \\ \partial_{c_1} \varepsilon(k|k-1,\theta) \\ \vdots \\ \partial_{c_{n_C}} \varepsilon(k|k-1,\theta) \end{bmatrix} \in \mathbb{R}^{n_A+n_B+n_C} \quad \text{où} \quad \partial_{x_i} \varepsilon(k|k-1,\theta) = \frac{\partial \varepsilon(k|k-1,\theta)}{\partial x_i}$$

$$x_i \in \{a_1, \dots, a_{n_A}, b_1 \dots b_{n_B}, c_1 \dots c_{n_C}\}$$

On a :

* $\partial_{a_j} \varepsilon(k|k-1,\theta^{[i]}) = \dfrac{q^{-j}}{C(q^{-1},\theta^{[i]})} y(k) = \dfrac{1}{C(q^{-1},\theta^{[i]})} y(k-j)$, $j = 1$ à n_A.

* $\partial_{b_j} \varepsilon(k|k-1,\theta^{[i]}) = -\dfrac{1}{C(q^{-1},\theta^{[i]})} u(k-d-j)$, $j = 1$ à n_B

* $\partial_{c_j} \varepsilon(k|k-1,\theta^{[i]}) = -\dfrac{1}{C(q^{-1},\theta^{[i]})} \varepsilon(k-j|k-j-1,\theta^{[i]})$, $j = 1$ à n_C.

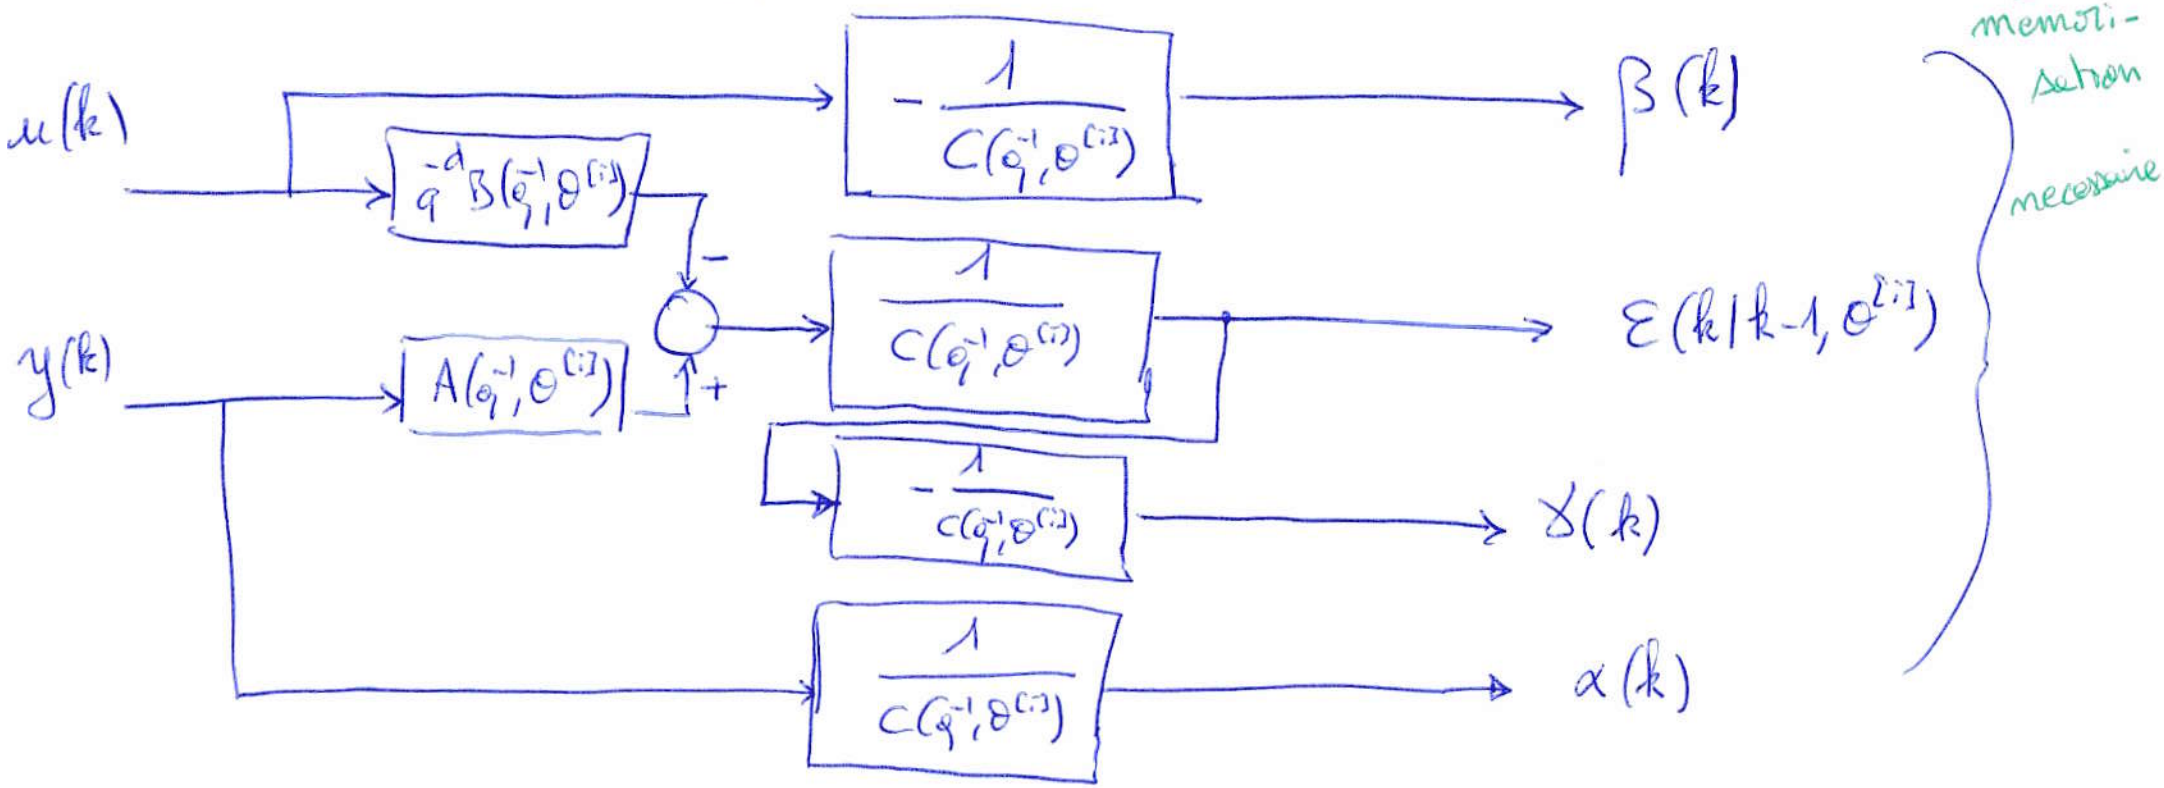
Posons : $\alpha(k-j) = \dfrac{1}{C(q^{-1},\theta^{[i]})} y(k-j)$

$\beta(k-j) = \dfrac{1}{C(q^{-1},\theta^{[i]})} u(k-d-j)$

et $\gamma(k-j) = -\dfrac{1}{C(q^{-1},\theta^{[i]})} \varepsilon(k-j|k-j-1,\theta^{[i]})$

$$\nabla_\theta \varepsilon(k|k-1,\theta^{[i]}) = \begin{bmatrix} \alpha(k-1) \\ \vdots \\ \alpha(k-n_A) \\ \beta(k-d-1) \\ \vdots \\ \beta(k-d-n_B) \\ \gamma(k-1) \\ \vdots \\ \gamma(k-n_C) \end{bmatrix} \longrightarrow$$

Signal recherché à construire à chaque instant, pour le vecteur des paramètres $\theta^{[i]}$ connu, en vue d'obtenir $\theta^{[i+1]}$.



Remarque : $\theta^{[i+1]} = \theta^{[i]} - \mu \frac{1}{n} \nabla_\theta J_N(\theta)\Big|_{\theta=\theta^{[i]}}$

méthode du gradient à pas fixe $\mu > 0$.

Robuste et simple mais convergence lente.

$$\theta^{[i+1]} = \theta^{[i]} - \left(H_\theta J_N(\theta)\Big|_{\theta=\theta^{[i]}} \right)^{-1} \nabla_\theta J_N(\theta)\Big|_{\theta=\theta^{[i]}}$$

méthode de Newton :

convergence rapide (en itérations) mais coûteuse en volume de calcul.