Algorithme récursif des moindres carrés.

Rappel : pour une structure de type ARX

où $$y(k) = \frac{q^{-d} B(q^{-1}, \theta)}{A(q^{-1}, \theta)} u(k) + \frac{1}{A(q^{-1}, \theta)} e(k)$$

on a $$y(k) = \theta^T \varphi(k-1) + e(k)$$
$$= \hat{y}(k|k-1, \theta) + e(k)$$

où $\theta^T = [a_1 \dots a_{n_A} \; b_1 \dots b_{n_B}]$ et $\varphi(k-1) = \begin{bmatrix} -y(k-1) \\ \vdots \\ -y(k-n_A) \\ u(k-d-1) \\ \vdots \\ u(k-d-n_B) \end{bmatrix}$

On a montré que $$\hat{\theta} = \arg \min_{\theta} \sum_{k=1}^{N} \left(y(k) - \hat{y}(k|k-1, \theta) \right)^2$$

$$= \left(\sum_{k=1}^{N} \varphi(k-1) \varphi(k-1)^T \right)^{-1} \sum_{k=1}^{N} \varphi(k-1) y(k) .$$

Remarque : $\hat{\theta}(N)$, dépend du nombre d'échantillons N.

Posons $F(t) := \left(\sum_{k=1}^{t} \varphi(k-1)\,\varphi(k-1)^T \right)^{-1}$.

On a $F(t)^{-1} = \sum_{k=1}^{t} \varphi(k-1)\varphi(k-1)^T$.

Ainsi: $\Theta(t) = F(t) \sum_{k=1}^{t} \varphi(k-1)\,y(k)$.

A $t+1$, on a $\Theta(t+1) = F(t+1) \sum_{k=1}^{t+1} \varphi(k-1)\,y(k)$.

$$F(t+1)^{-1} = \sum_{k=1}^{t+1} \varphi(k-1)^T \varphi(k-1) = \sum_{k=1}^{t} \varphi(k-1)\varphi(k-1)^T + \varphi(t)\,\varphi(t)^T$$

$$= F(t)^{-1} + \varphi(t)\,\varphi(t)^T$$

Donc $F(t+1) = \left(F(t)^{-1} + \varphi(t)\varphi(t)^T \right)^{-1}$. Comment calculer plus simplement cette quantité matricielle ?

Formule de Sherman Morrison Woodbury :

Soient $x, y \in \mathbb{R}^n$ et $A \in \mathbb{R}^{n \times n}$ une matrice supposée inversible.

* $\det(A + x y^T) = (1 + y^T A^{-1} x) \det A$.

$\longrightarrow \det(A + x y^T) \neq 0 \iff y^T A^{-1} x \neq -1$.

Dans ce cas, si $y^T A^{-1} x \neq -1$, alors

$$\boxed{(A + x y^T)^{-1} = A^{-1} - (1 + y^T A^{-1} x)^{-1} A^{-1} x y^T A^{-1}}.$$

On applique cette formule au calcul de

$$F(t+1) = \left(F(t)^{-1} + \varphi(t)\varphi(t)^T\right)^{-1}$$

$$= F(t) - \frac{F(t)\varphi(t)\varphi(t)^T F(t)}{1 + \varphi(t)^T F(t) \varphi(t)}.$$

On utilise ce résultat dans l'expression de $\theta(t+1) = F(t+1) \sum_{k=1}^{t+1} \varphi(k-1) y(k)$.

Il vient :

$$\theta(t+1) = F(t) \sum_{k=1}^{t+1} \varphi(k-1) y(k) - \frac{F(t)\varphi(t)\varphi(t)^T F(t)}{1 + \varphi(t)^T F(t) \varphi(t)} \sum_{k=1}^{t+1} \varphi(k-1) y(k)$$

$$= \underbrace{F(t) \sum_{k=1}^{t} \varphi(k-1) y(k)}_{\theta(t)} + F(t)\varphi(t) y(t+1) - \frac{F(t)\varphi(t)\varphi(t)^T F(t)}{1 + \varphi(t)^T F(t) \varphi(t)} \sum_{k=1}^{t+1} \varphi(k-1) y(k).$$

Le second membre est mis au même dénominateur :

$$\theta(t+1) = \theta(t) + \frac{F(t)\varphi(t)\,y(t+1) + F(t)\varphi(t)\varphi(t)^T F(t)\varphi(t)\,y(t+1) - F(t)\varphi(t)\varphi(t)^T F(t) \sum_{k=1}^{t+1} \varphi(k-1)\,y(k)}{1 + \varphi(t)^T F(t)\varphi(t)}$$

$$= \theta(t) + \frac{F\varphi\, y(t+1) + F\varphi\varphi^T F\varphi\, y(t+1) - F\varphi\varphi^T F\varphi\, y(t+1) - F\varphi\varphi^T F \underbrace{\sum_{k=1}^{t} \varphi(k-1)\,y(k)}_{\theta(t)}}{1 + \varphi(t)^T F(t)\varphi(t)}$$

$$= \theta(t) + \frac{F(t)\varphi(t)\,y(t+1) - F(t)\varphi(t)\varphi(t)^T\theta(t)}{1 + \varphi(t)^T F(t)\varphi(t)}$$

or $\varphi(t)^T\theta(t) = \hat{y}(t+1|t)$

Posons $\varepsilon(t+1|t) := y(t+1) - \hat{y}(t+1|t)$

$= y(t+1) - \theta(t)^T\varphi(t)$.

On en déduit l'algorithme récursif :

$$\theta(t+1) = \theta(t) + F(t)\varphi(t)\frac{\varepsilon(t+1|t)}{1 + \varphi(t)^T F(t)\varphi(t)}$$

$$\varepsilon(t+1|t) = y(t+1) - \theta(t)^T\varphi(t)$$

$$F(t) = F(t-1) - \frac{F(t-1)\varphi(t-1)\varphi(t-1)^T F(t-1)}{1 + \varphi(t-1)^T F(t-1)\varphi(t-1)}$$

Algorithme MCR (Moindres Carrés Récursifs)

Remarques :

* $$\Delta\Theta(t+1) = \underbrace{F(t)}_{\text{matrice carrée}} \underbrace{\varphi(t)}_{\text{vecteur}} \underbrace{\frac{y(t+1) - \Theta(t)^T \varphi(t)}{1 + \varphi(t)^T F(t) \varphi(t)}}_{\text{scalaire}} \in \mathbb{R}^{n_A + n_B}$$

* Algorithme récursif $\Longrightarrow$ initialisation de $\Theta(t)$ et $F(t)$.

  En pratique, on prend $F(0) = \frac{1}{\delta} I_{n_A+n_B}$ où $0 < \delta < 1$.

  $\Theta(0)$ est pris quelconque si aucune info a priori.

  Sinon, on peut choisir $\Theta(0) = \hat{\Theta}_{ARX}$ obtenu hors-ligne à partir d'un jeu de données antérieures.

* Pour un même jeu de données :

  $\hat{\Theta}(N)$ est le même, que ce soit "hors-ligne" ou via MCR, si ce dernier est démarré à $k = n_A + n_B$ pour que $F(n_A+n_B)$ devienne inversible (sous-réserve d'excitation persistante).

* La formule récursive du gain matriciel $F(t)$ permet de montrer (admis) qu'il est "décroissant" avec t.
En effet, dans le cas scalaire :

$$F(t) = \frac{F(t-1)}{1 + \varphi(t-1)^2 F(t-1)} \leq F(t-1).$$

$$\Longrightarrow \|\Delta\theta(t)\| \xrightarrow[t\to\infty]{} 0$$

* L'algo. des MCR donne de moins en moins de poids aux nouvelles mesures, (décroissance de $F(t)$).

$\Longrightarrow$ peu adapté au cas de paramètres (légèrement) variable dans le temps.

* ⚠ $F(t)^{-1}$ peut devenir SINGULIÈRE, donc NON inversible.
C'est le cas si les nouvelles observations n'apportent aucune nouvelle info.
Dans ce cas, on ajoute $\alpha \mathbb{1}_{n_A+n_B}$ à l'expression de $F(t)$, α très petit.

Algorithme MCR avec facteur d'oubli

Dans le cas où les paramètres évoluent lentement au cours du temps, il convient de donner PLUS d'importance aux mesures récentes
⇒ pénaliser les mesures anciennes de PLUS en PLUS avec le temps.

Idée : Dans le critère à minimiser, on donne un poids unité à l'instant présent t, un poids λ à l'instant $t-1$, λ^2 à l'instant $t-2$ etc... où $0 < \lambda < 1$.

$$J_t(\theta) = \sum_{k=1}^{t} \lambda^{t-k} \varepsilon(k|k-1,\theta)^2 .$$

On montre que cela revient à avoir :

$$F(t+1)^{-1} = \lambda F(t)^{-1} + \varphi(t)\varphi(t)^T$$

$$v(t+1) = \lambda v(t) + \varphi(t) y(t+1) \quad \text{avec} \quad v(t) := \sum_{k=1}^{t} \varphi(k-1) y(t)$$

ce qui conduit à l'algorithme des MCR avec facteur d'oubli :

$$\theta(t+1) = \theta(t) + F(t)\varphi(t)\frac{\varepsilon(t+1|t)}{\lambda + \varphi(t)^T F(t)\varphi(t)}$$

$$\varepsilon(t+1|t) = y(t+1) - \theta(t)^T \varphi(t)$$

$$F(t) = \frac{1}{\lambda} F(t-1) - \frac{1}{\lambda}\frac{F(t-1)\varphi(t-1)\varphi(t-1)^T F(t-1)}{\lambda + \varphi(t-1)^T F(t-1)\varphi(t-1)}$$

En pratique, on prend $0{,}95 < \lambda < 1$ pour éviter d'avoir un gain matriciel $F(t)$ qui fluctue "trop" fortement.

⚠ dès qu'on a $\varphi(t) = 0$, $F(t) = \frac{1}{\lambda} F(t-1)$ qui peut diverger ⟹ surveiller l'algorithme
- → l'arrêter
- → "borner" $F(t)$.