Méthodes pour la confiance (6/7) - 1h30 - Cours
Compréhension et modélisation des réseaux de neurones

SIALV : Service Intelligence Artificielle Langage et Vision
Mohamed TAMAAZOUSTI
mohamed.tamaazousti@cea.fr

LA RÉVOLUTION DU DEEP LEARNING

IMAGENET CHALLENGE



IMAGENET CHALLENGE



(a) ImageNet Synset: One sample image from each category



(b) Corel-1000 Dataset: Sample images from each category



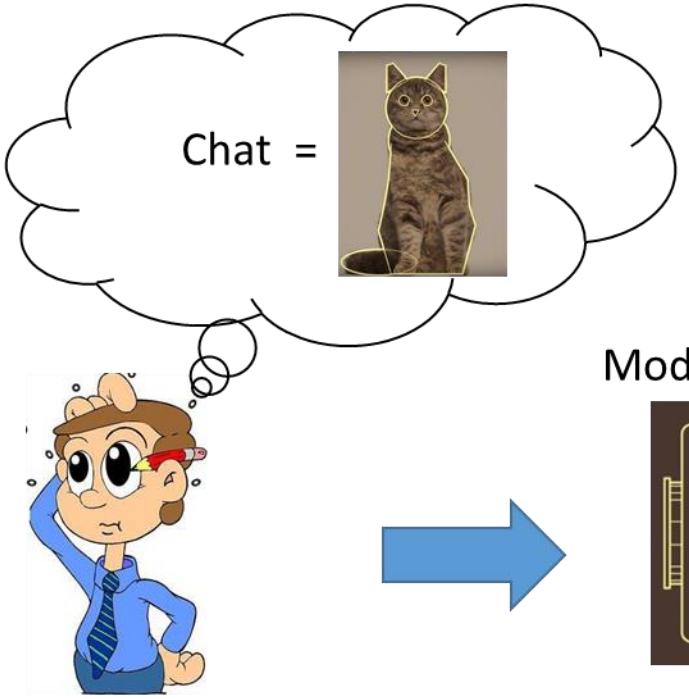
(c) Caltech-256 Dataset: One sample image from each category



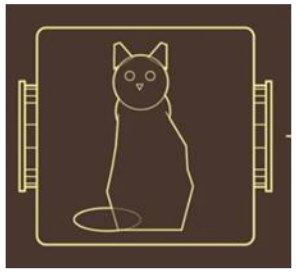
(d) Caltech-101 Dataset: One sample image from each category

IA 1.0 : HARD CODING

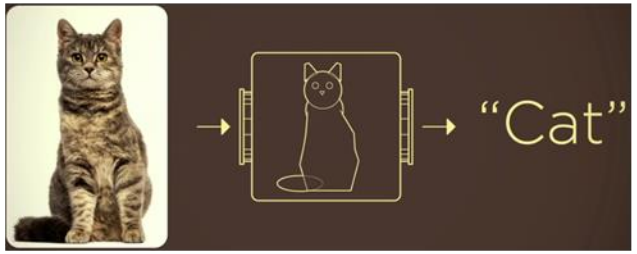
Construction du modèle :

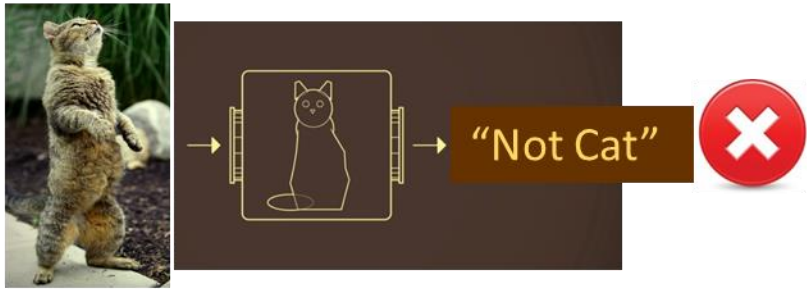


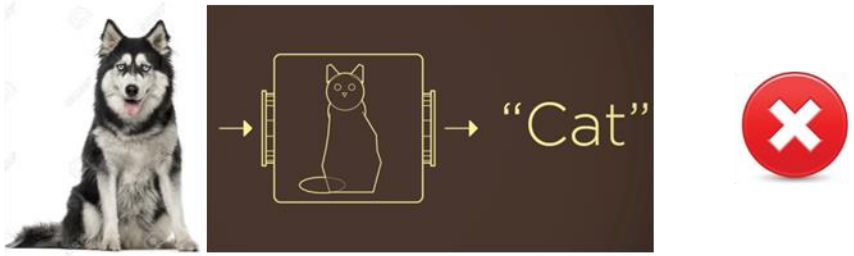
Modèle 1.0 du chat



Inférence :





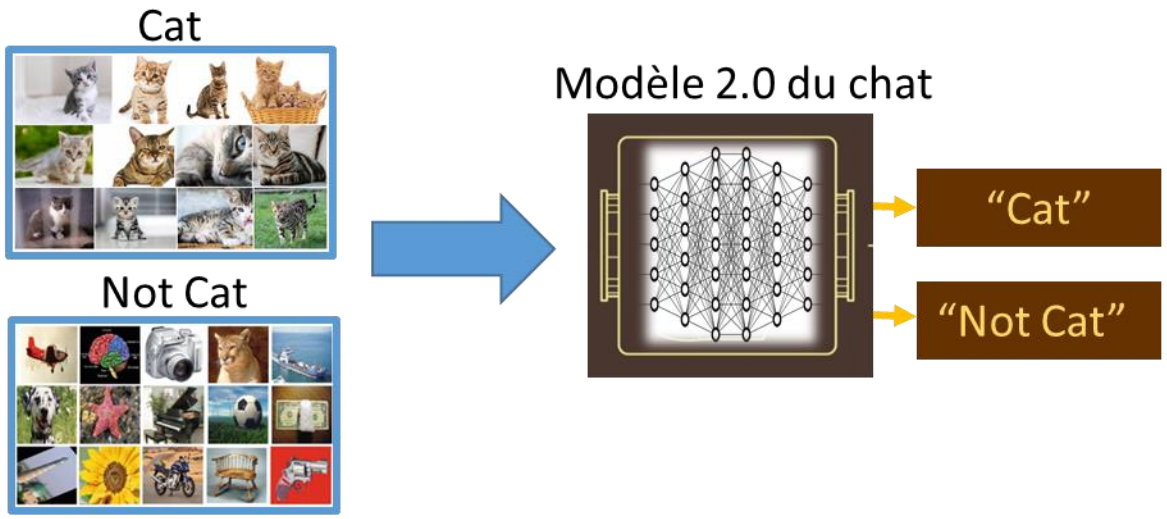


- Limité à la connaissance Humaine
- Durable (confiance + Green)

IA 2.0 : DEEP LEARNING

Construction du modèle :

- Basée sur la data



Inférence :

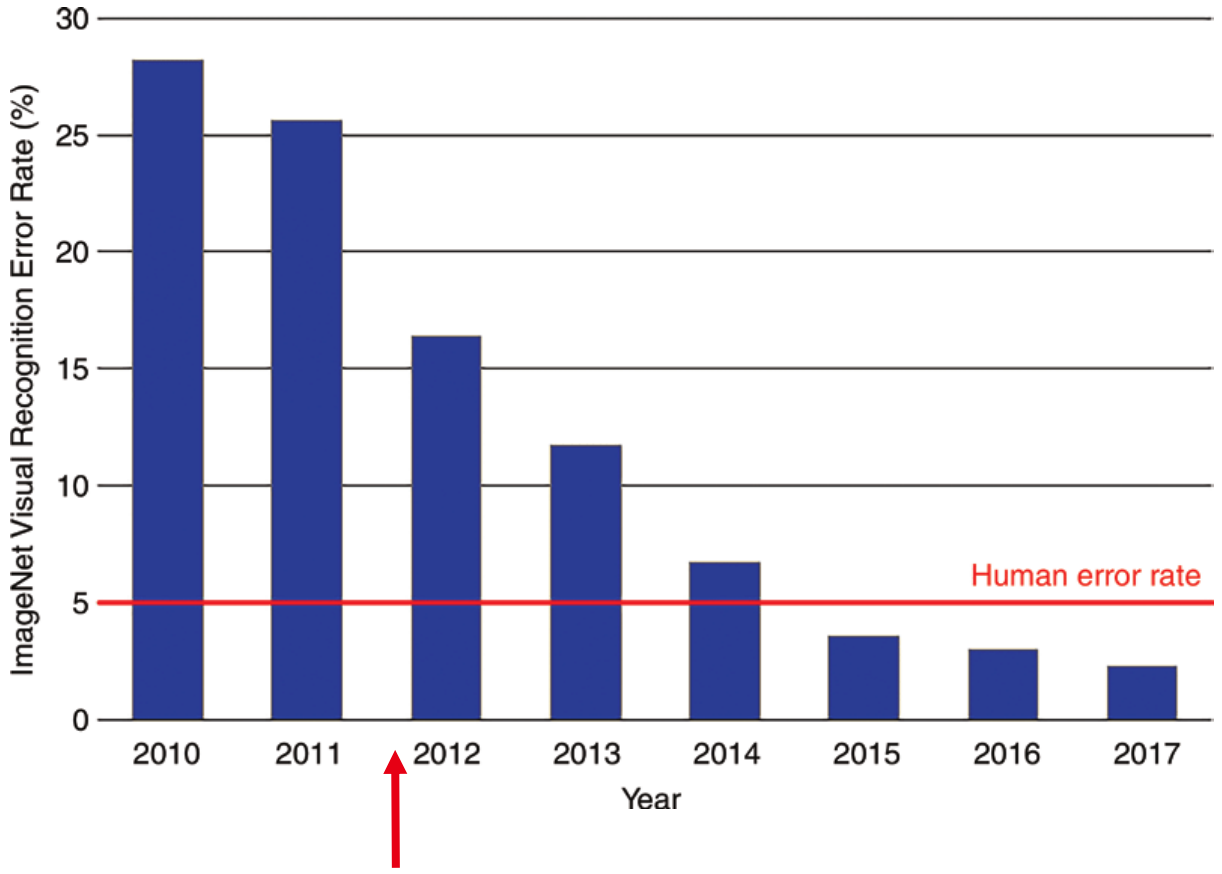


Au-delà de la connaissance Humaine

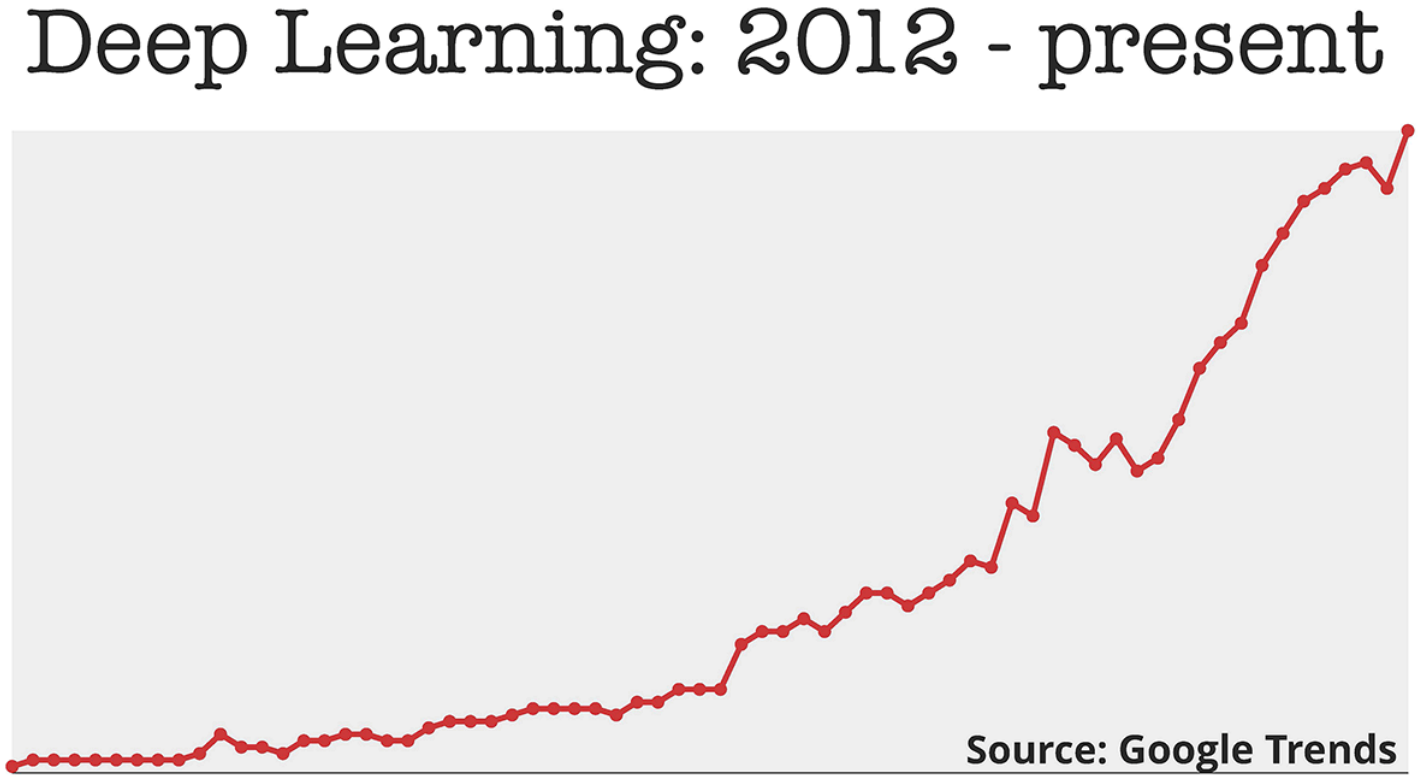
Pas durable (Opaque + Couteux en terme de calcul)

LA RÉVOLUTION DU DEEP LEARNING

- **Error rates on the ImageNet Large-Scale Visual Recognition Challenge. Accuracy dramatically improved with the introduction of deep learning in 2012 and continued to improve thereafter. Humans perform with an error rate of approximately 5%.**



TENDANCE : VERS UNE DÉMOCRATISATION DE L'INTELLIGENCE ARTIFICIELLE



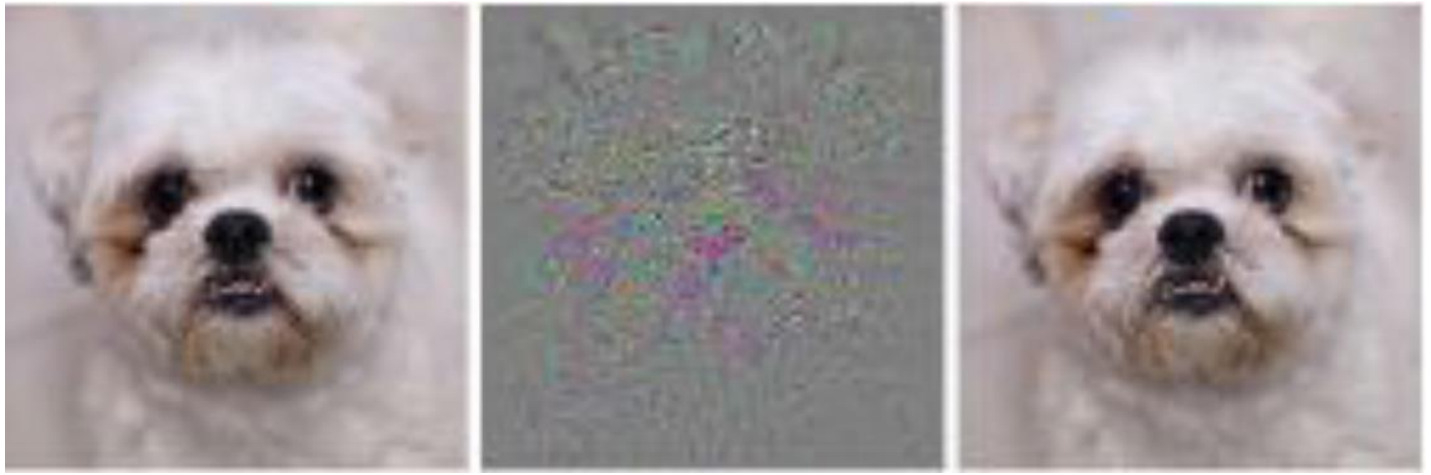
POURQUOI CHERCHER À COMPRENDRE LE DEEP LEARNING ?

PROBLÈME 1 : LE MANQUE DE FIABILITÉ DES DNN

- **DNN : Deep Neural Networks**
- **Szegedy, Zaremba, Sutskever, Bruna, Erhan, Goodfellow, Fergus, "*Intriguing properties of neural networks*", ICLR 2014**

$$\tilde{\mathfrak{I}} = \mathfrak{I} + \epsilon$$
$$avec\ \epsilon = 10^{-2}\mathfrak{I}$$

$\mathfrak{I}$ ϵ $\tilde{\mathfrak{I}}$

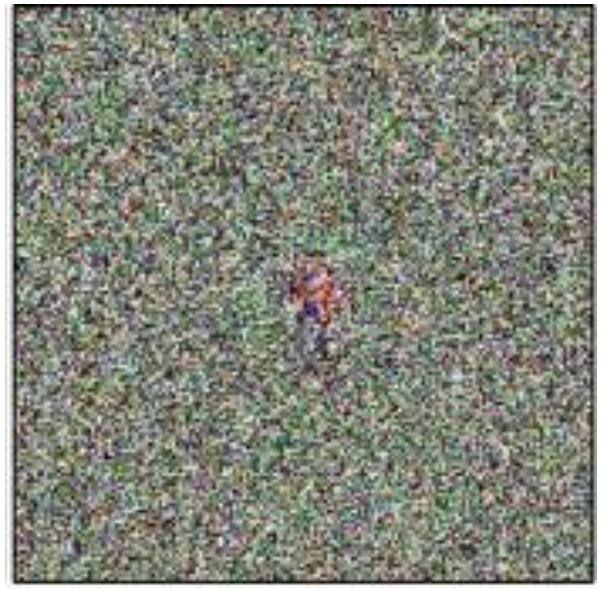


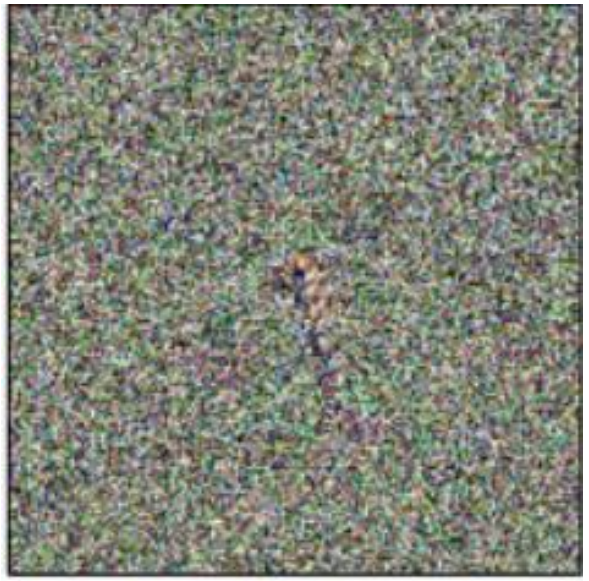
Prédiction: chien

Prédiction: autruche

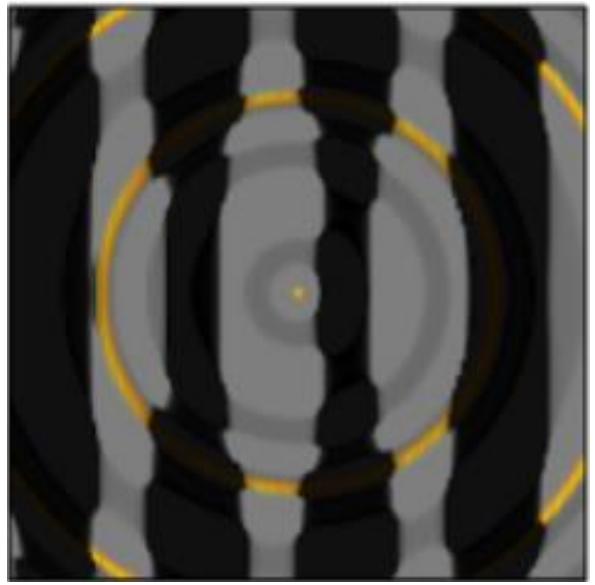
PROBLÈME 1 : LE MANQUE DE FIABILITÉ DES DNN

- Nguyen *et al.* "*Deep Neural Networks are Easily Fooled: High Confidence Predictions for Unrecognizable Images*", CVPR 2015





Guépard



Pingouin

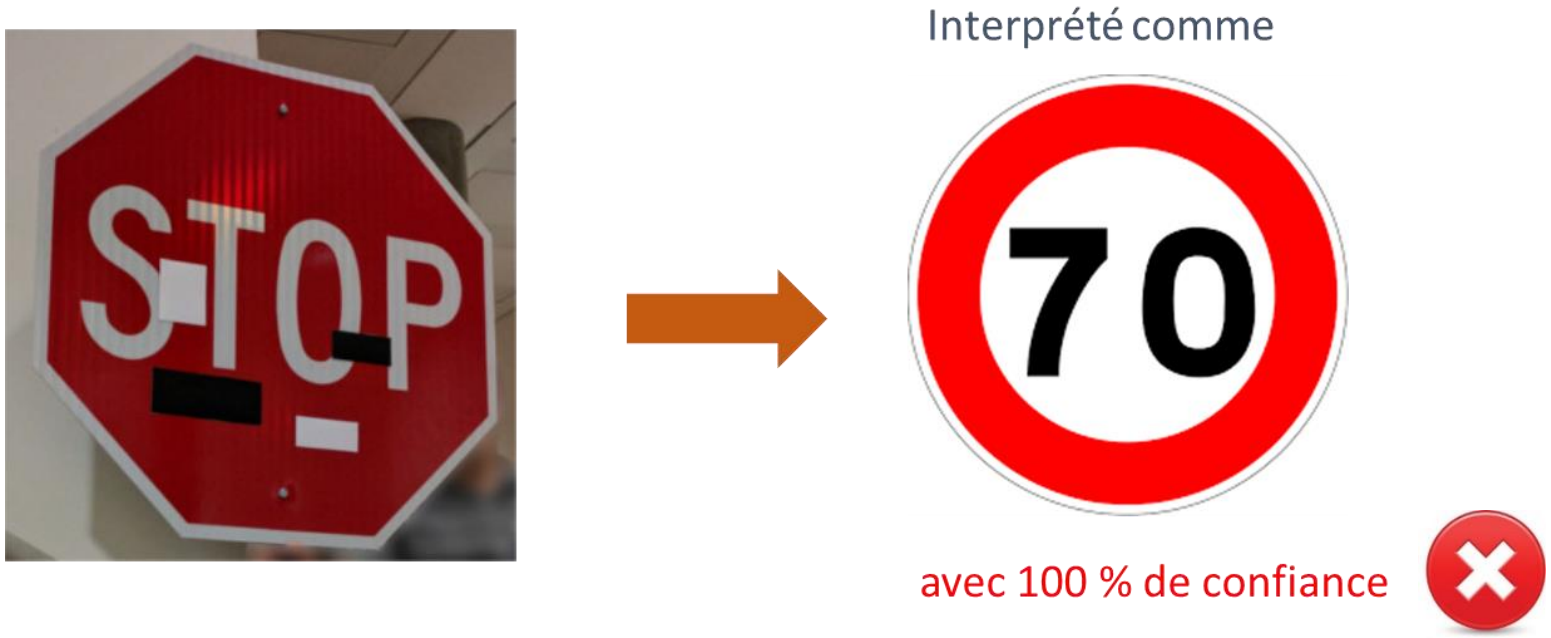


étoile de mer

Avec en moyenne 99,6 % de confiance

PROBLÈME 1 : LE MANQUE DE FIABILITÉ DES DNN

- Evtimov et al, *"Robust Physical-World Attacks on Deep Learning Visual Classification"*, CVPR 2018

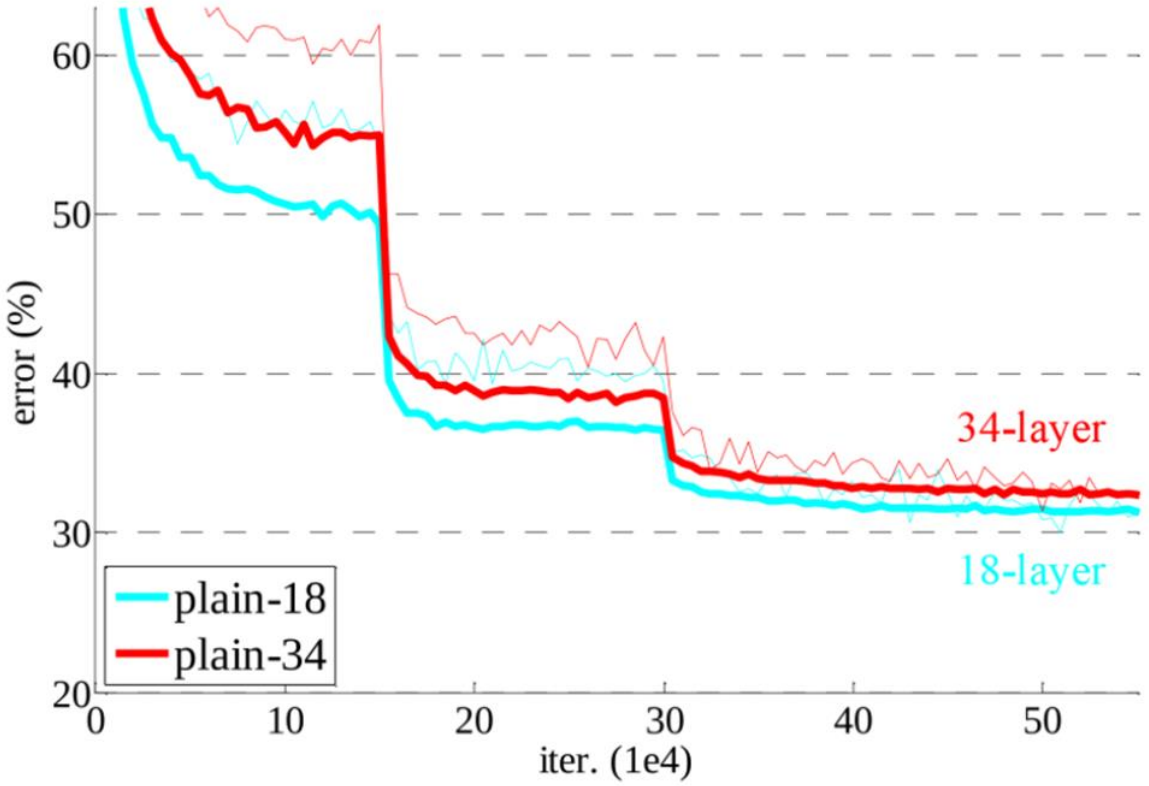


PROBLÈME 1 : LE MANQUE DE FIABILITÉ DES DNN



PROBLÈME 2 : LA CONSOMMATION EXCESSIVE DU DEEP LEARNING

- **Le choix des hyperparamètres c'est beaucoup de cuisine :**
  - K. He, X. Zhang, S. Ren and J. Sun, "*Deep residual learning for image recognition*", CVPR 2016.

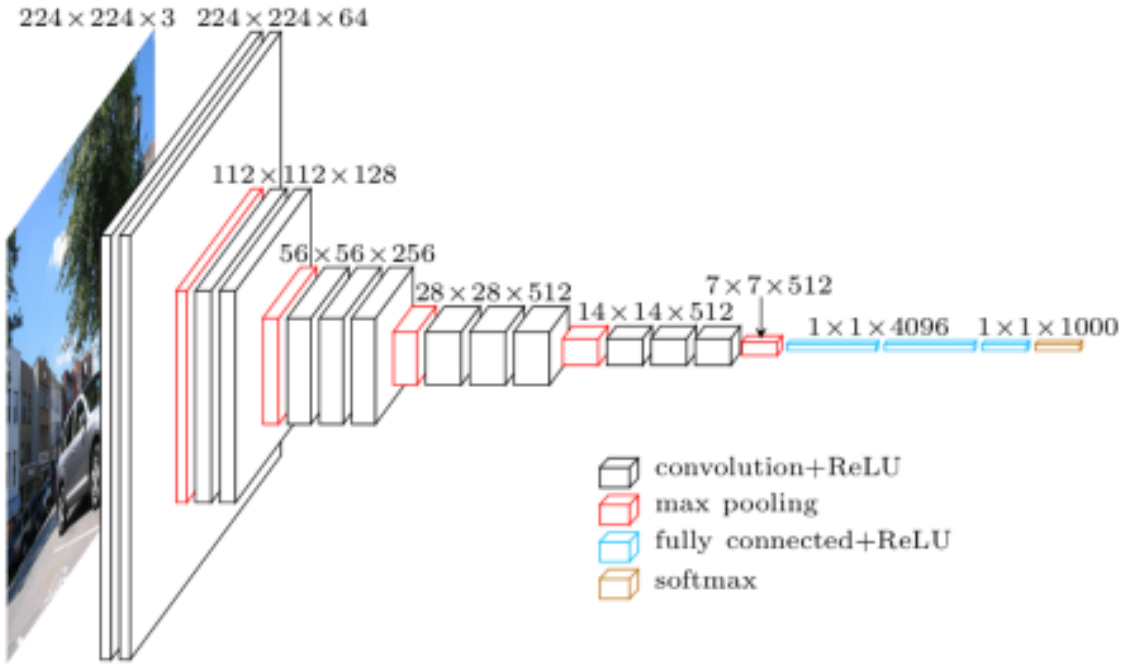




PROBLÈME 2 : LA CONSOMMATION EXCESSIVE DU DEEP LEARNING

- **Un exemple concret : Architecture de VGG Net**
  - K. Simonyan and A. Zisserman. "*Very deep convolutional networks for large-scale image recognition*" arXiv preprint arXiv:1409.1556 (2014)
  - Cité 52229 fois sur Google Scholar le 11 Février 2021

ConvNet Configuration					
A	A-LRN	B	C	D	E
11 weight layers	11 weight layers	13 weight layers	16 weight layers	16 weight layers	19 weight layers
input (224 × 224 RGB image)					
conv3-64	conv3-64 **LRN**	conv3-64 **conv3-64**	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64
maxpool					
conv3-128	conv3-128	conv3-128 **conv3-128**	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128
maxpool					
conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256 **conv1-256**	conv3-256 conv3-256 **conv3-256**	conv3-256 conv3-256 **conv3-256**
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 **conv1-512**	conv3-512 conv3-512 **conv3-512**	conv3-512 conv3-512 **conv3-512**
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 **conv1-512**	conv3-512 conv3-512 **conv3-512**	conv3-512 conv3-512 **conv3-512**
maxpool					
FC-4096					
FC-4096					
FC-1000					
soft-max					



Network	A	B	C	D	E
Nombre de paramètres (Millions)	133	133	134	138	144

PROBLÈME 2 : LA CONSOMMATION EXCESSIVE DU DEEP LEARNING



THE DAILY NEWSLETTER
Sign up to our daily email newsletter

NewScientist

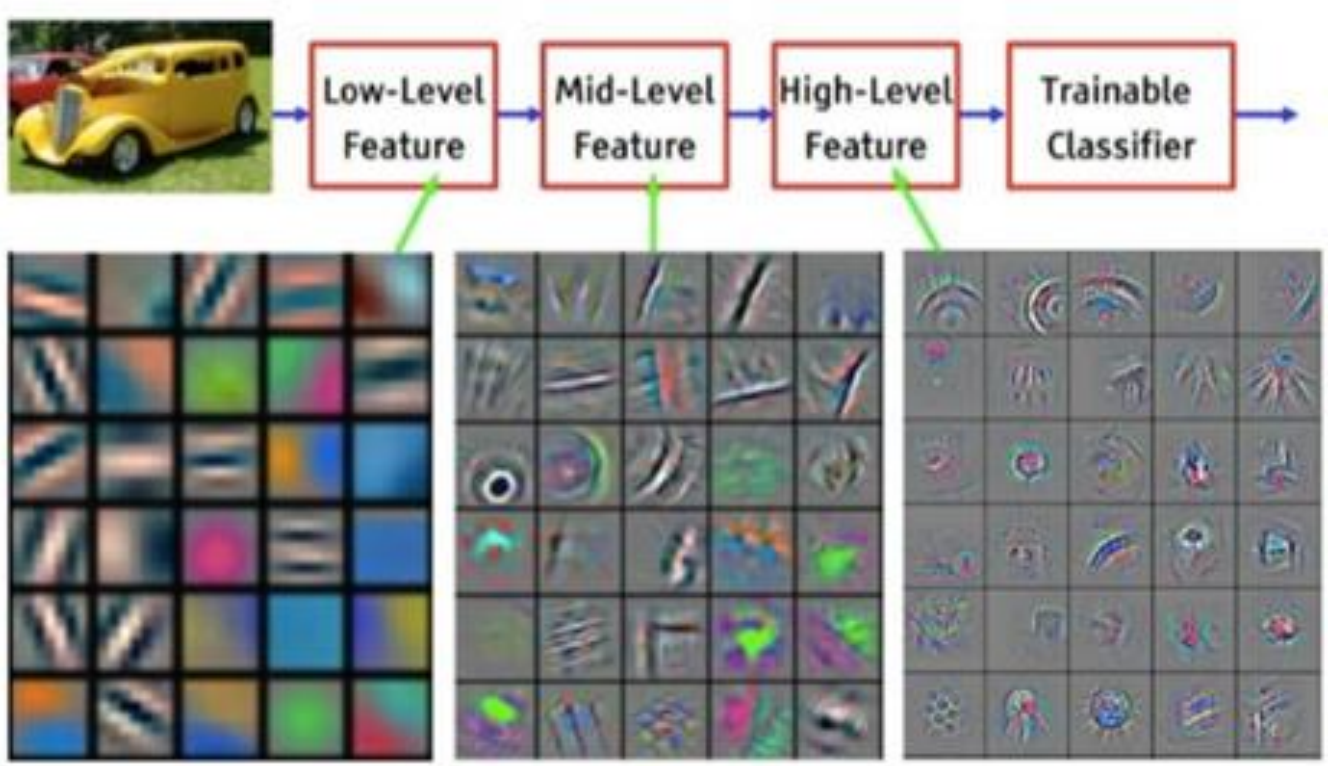
News Technology Space Physics Health Environment Mind Crosswords Video

Creating an AI can be five times worse for the planet than a car

COMMENT EST ABORDÉE LA COMPRÉHENSION DES RÉSEAUX DE NEURONES ?

COMPRÉHENSION EMPIRIQUE PAR VISUALISATION DES FILTRES

- Zeiler, Matthew D., and Rob Fergus. "Visualizing and understanding convolutional networks." European conference on computer vision. Springer, Cham, 2014.

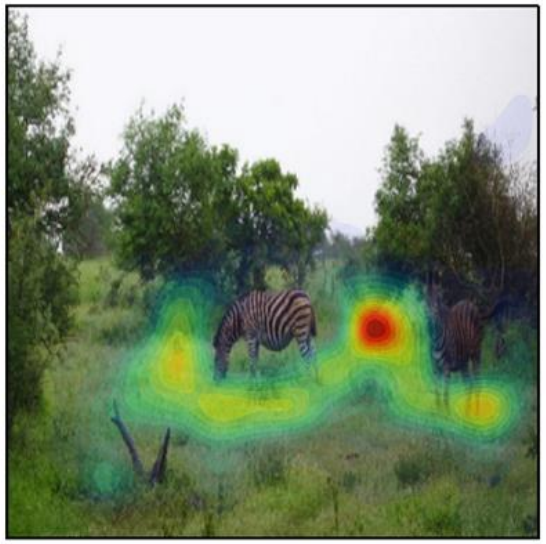


COMPRÉHENSION EMPIRIQUE PAR VISUALISATION DES FILTRES

- Goebel, Randy, et al. "Explainable ai: the new 42?." International cross-domain conference for machine learning and knowledge extraction. Springer, Cham, 2018.

Q: Is this a zoo?

A: No



... because the zebras are standing in a green field.

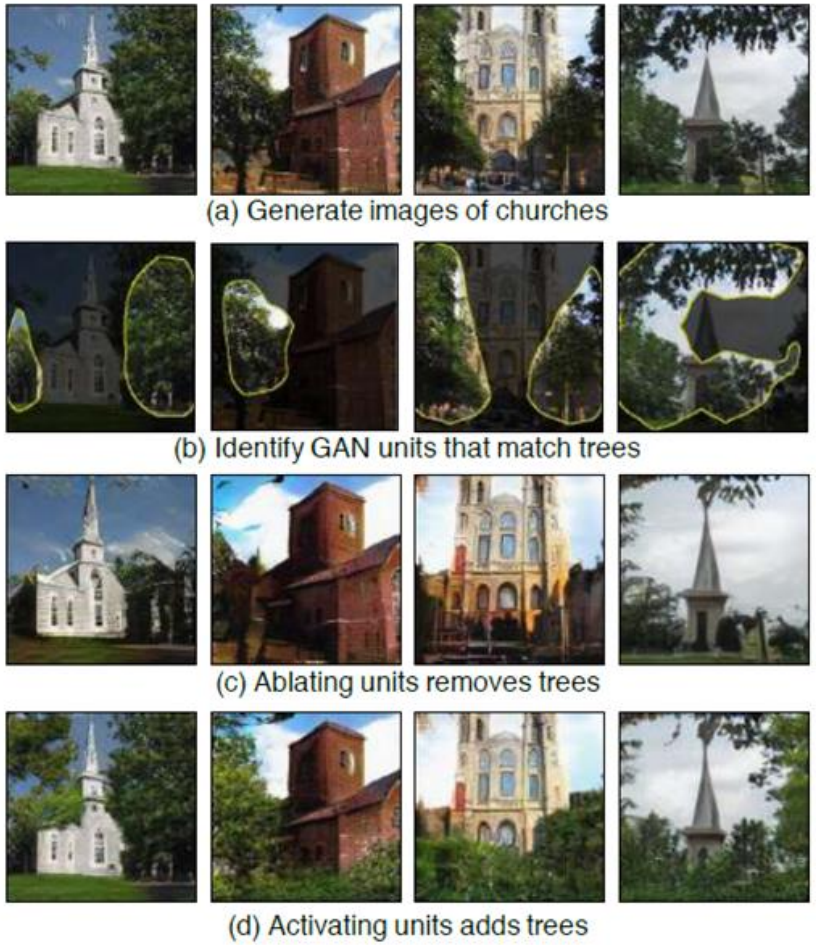
A: Yes



... because there are animals in an enclosure.

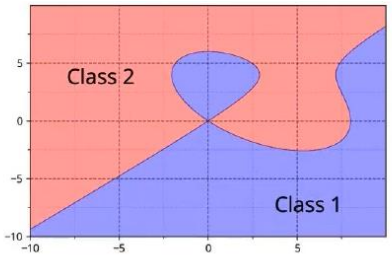
COMPRÉHENSION EMPIRIQUE PAR VISUALISATION DES FILTRES

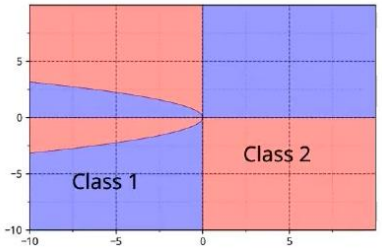
- Bau, David, et al. "Gan dissection: Visualizing and understanding generative adversarial networks." arXiv preprint arXiv:1811.10597 (2018).

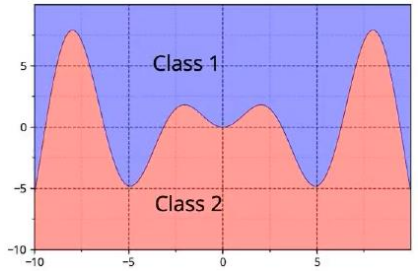


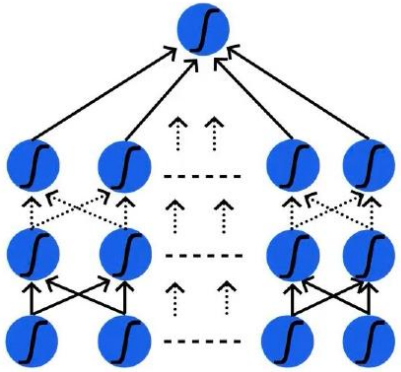
NEURAL NETWORK UNIVERSAL APPROXIMATION THEOREM

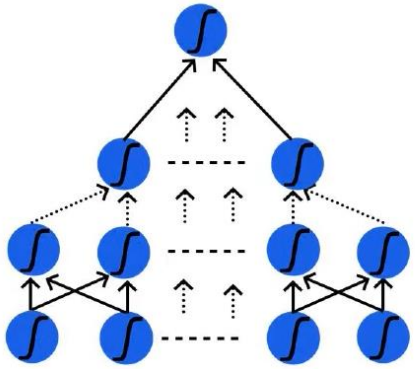
- Cybenko, George. "Approximation by superpositions of a sigmoidal function." *Mathematics of control, signals and systems* 2.4 (1989): 303-314.

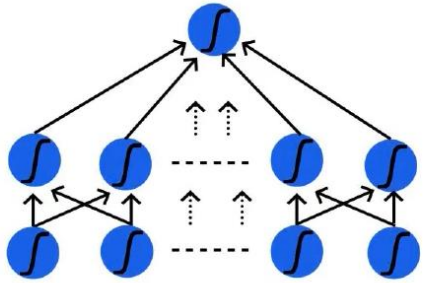








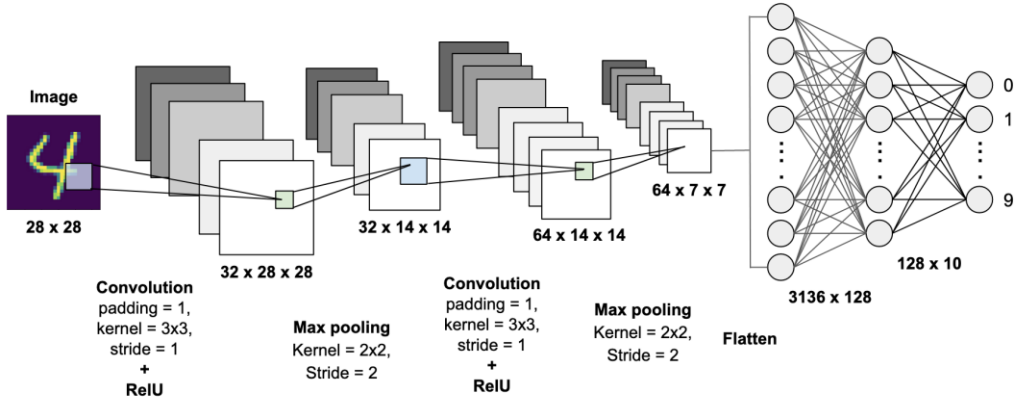




NEURAL NETWORK UNIVERSAL APPROXIMATION THEOREM

- **Most Universal Approximation Theorems can be parsed into two classes**
  1. Quantifies the approximation capabilities of neural networks with an arbitrary number of artificial neurons ("*arbitrary width*" case)
  2. Focuses on the case with an arbitrary number of hidden layers, each containing a limited number of artificial neurons ("*arbitrary depth*" case).

- **Universal Approximation Theorem for Convolutional Neural Network (CNN) architecture**
  - Zhou, Ding-Xuan. "Universality of deep convolutional neural networks." *Applied and computational harmonic analysis* 48.2 (2020): 787-794.
  - Heinecke, Andreas, Jinn Ho, and Wen-Liang Hwang. "Refinement and universal approximation via sparsely connected relu convolution nets." *IEEE Signal Processing Letters* 27 (2020): 1175-1179.



QUELLE GARANTIE A-T-ON D'ATTEINDRE CETTE APPROXIMATION EN PRATIQUE ?

- **En appliquant un algorithme d'optimisation inclus dans l'apprentissage ?**
  - Alors que la SGD n'a été rigoureusement analysé que pour les fonctions de loss convexe, dans l'apprentissage profond, la loss est une fonction non convexe en les paramètres du réseau. ➔ il n'y a donc aucune garantie que SGD trouve le minimum global.
    - Mark Schmidt, Nicolas Le Roux, and Francis Bach. Minimizing finite sums with the stochastic average gradient. Mathematical Programming, pages 1–30, 2013.

  - Yann N Dauphin, Razvan Pascanu, Caglar Gulcehre, Kyunghyun Cho, Surya Ganguli, and Yoshua Bengio. Identifying and attacking the saddle point problem in high-dimensional non-convex optimization. In Neural Information Processing Systems, pages 2933–2941, 2014.
  - A. Choromanska, M. Henaff, M. Mathieu, G.B Arous, and Y. LeCun. The loss surfaces of multilayer networks. In International Conference on Artificial Intelligence and Statistics, pages 192–204, 2015.

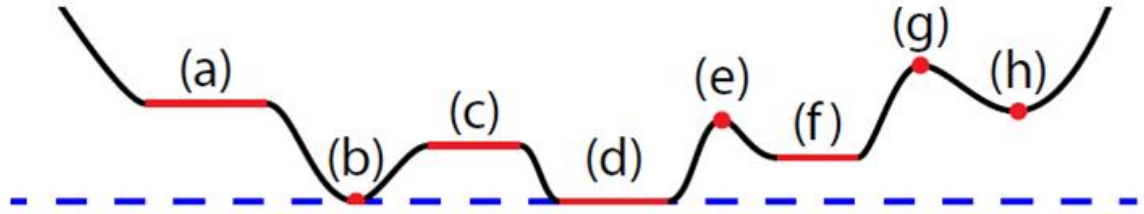


Fig. 2. Example critical points of a non-convex function (shown in red). (a,c) Plateaus. (b,d) Global minima. (e,g) Local maxima. (f,h) Local minima.

QUELLE GARANTIE A-T-ON D'ATTEINDRE CETTE APPROXIMATION EN PRATIQUE ?

- **En exploitant des données en quantité finie ?**
  - Aubin B., Maillard, A., Krzakala F., Macris N., & Zdeborová L. (2018). The committee machine: Computational to statistical gaps in learning a two-layer neural network. In Advances in Neural Information Processing Systems (NeurIPS)

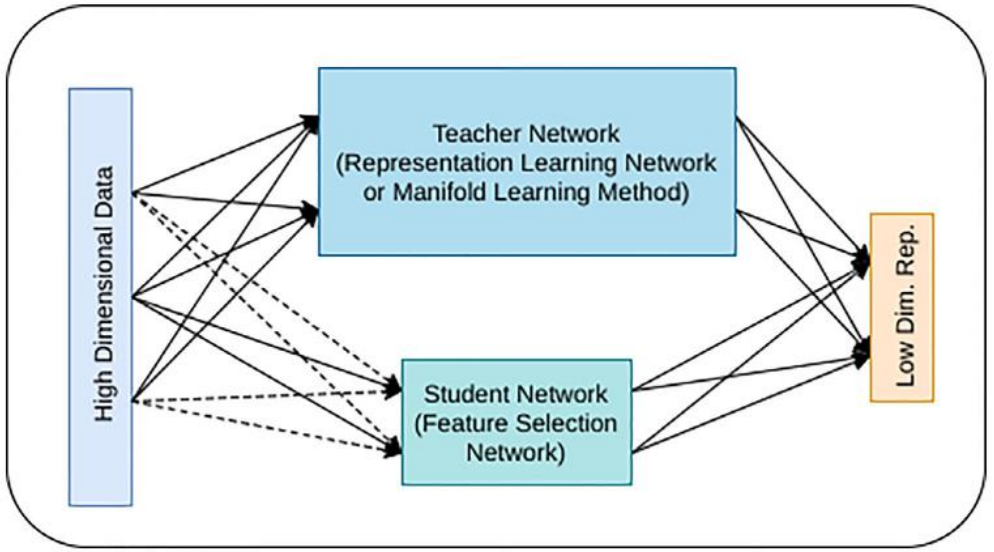
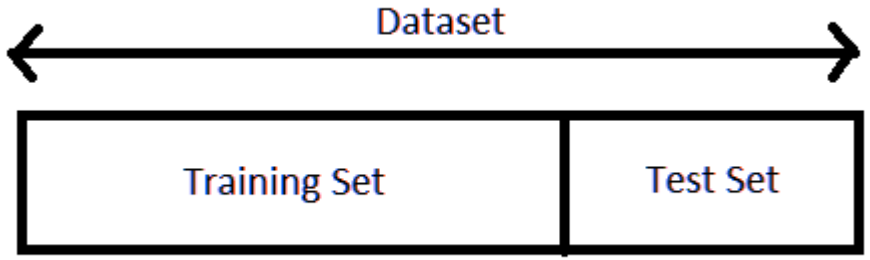
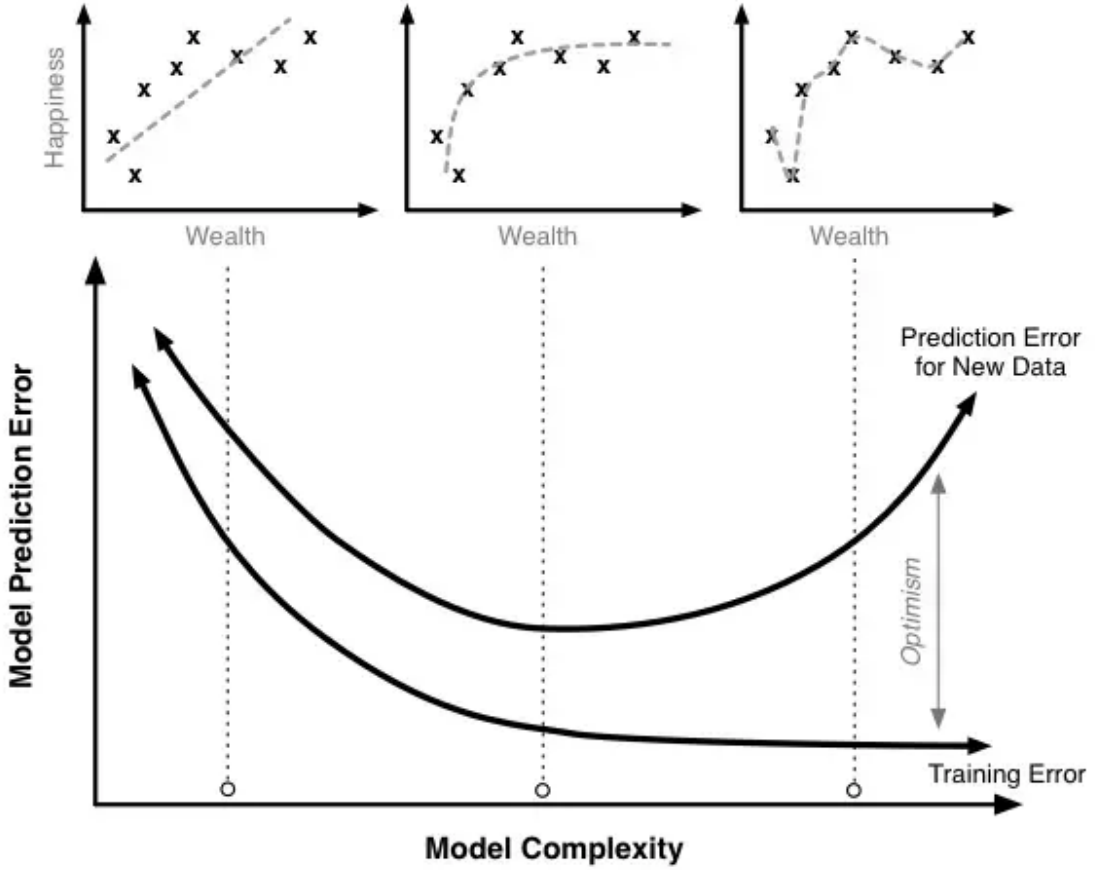


Fig. 1. The proposed teacher-student scheme for feature selection.

LA NOTION DE GÉNÉRALISATION EN MACHINE LEARNING





CAPACITÉS DE GÉNÉRALISATION DES DNN

- **Des résultats théoriques montrent que le nombre d'exemples d'apprentissage nécessaires à une bonne généralisation augmente de manière polynomiale avec la taille du réseau et donc avec le nombre de paramètres le caractérisant.**
  - Bartlett, P. L. & Maass W. (2003). Vapnik-Chervonenkis dimension of neural nets. The handbook of brain theory and neural networks, 1188-1192

- **Or, en pratique, les réseaux sont appris avec beaucoup moins de données que le nombre de paramètres.**
  - Zhang, C., Bengio, S., Hardt, M., Recht, B., & Vinyals, O. (2016). Understanding deep learning requires rethinking generalization. *arXiv preprint arXiv:1611.03530*.

D'OÙ VIENT LA CAPACITÉ DE GÉNÉRALISATION DES DNN

- **Cette propriété de généralisation est d'une part associée à la présence d'un terme de régularisation dans la fonction de coût utilisée dans l'apprentissage,**
  - Schölkopf, Bernhard, Alexander J. Smola, and Francis Bach. *Learning with kernels: support vector machines, regularization, optimization, and beyond*. MIT press, 2002.
  - Mairal, Julien. "End-to-End Kernel Learning with Supervised Convolutional Kernel Networks." *Advances in Neural Information Processing Systems (NIPS)*, 2016.

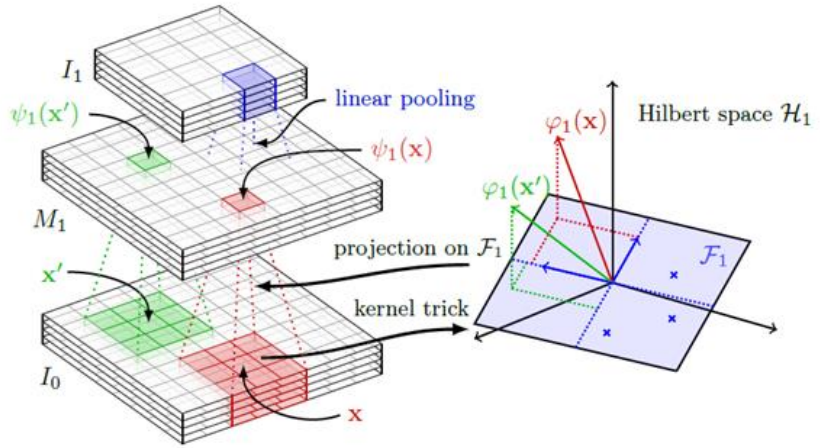


Figure 1: Our variant of convolutional kernel networks, illustrated between layers 0 and 1. Local patches (receptive fields) are mapped to the RKHS $\mathcal{H}_1$ via the kernel trick and then projected to the finite-dimensional subspace $\mathcal{F}_1 = \text{Span}(\varphi(\mathbf{z}_1), \ldots, \varphi(\mathbf{z}_{p_1}))$. The small blue crosses on the right represent the points $\varphi(\mathbf{z}_1), \ldots, \varphi(\mathbf{z}_{p_1})$. With no supervision, optimizing $\mathcal{F}_1$ consists of minimizing projection residuals. With supervision, the subspace is optimized via back-propagation. Going from layer k to layer $k+1$ is achieved by stacking the model described here and shifting indices.

Given a positive definite kernel K on images, the classical empirical risk minimization formulation consists of finding a prediction function in the RKHS $\mathcal{H}$ associated to K by minimizing the objective

$$\min_{f \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^{n} L(y_i, f(I_0^i)) + \frac{\lambda}{2} \|f\|_{\mathcal{H}}^2, \qquad (5)$$

D'OÙ VIENT LA CAPACITÉ DE GÉNÉRALISATION DES DNN

- **Cette propriété de généralisation est d'autre part liée à l'architecture qui apporte une stabilité vis-à-vis des déformations de la donnée : un réseau est bon si sa sortie est invariante aux déformations non significatives que subirait la donnée d'entrée.**
  - Mallat, Stéphane. "Understanding deep convolutional networks." *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences* 374.2065 (2016): 20150203.

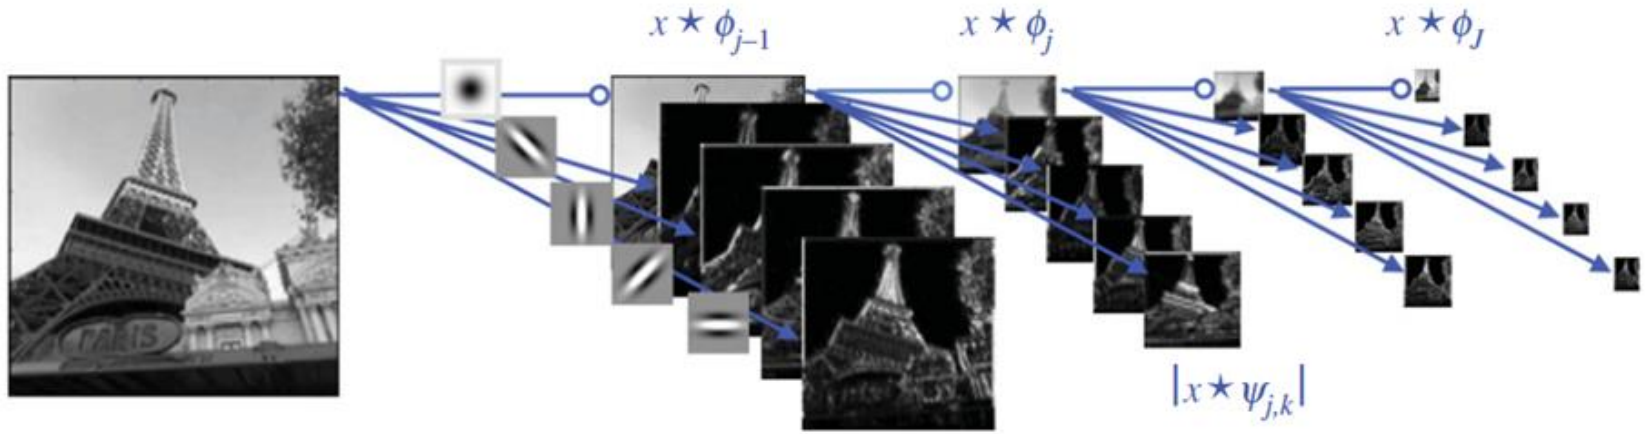
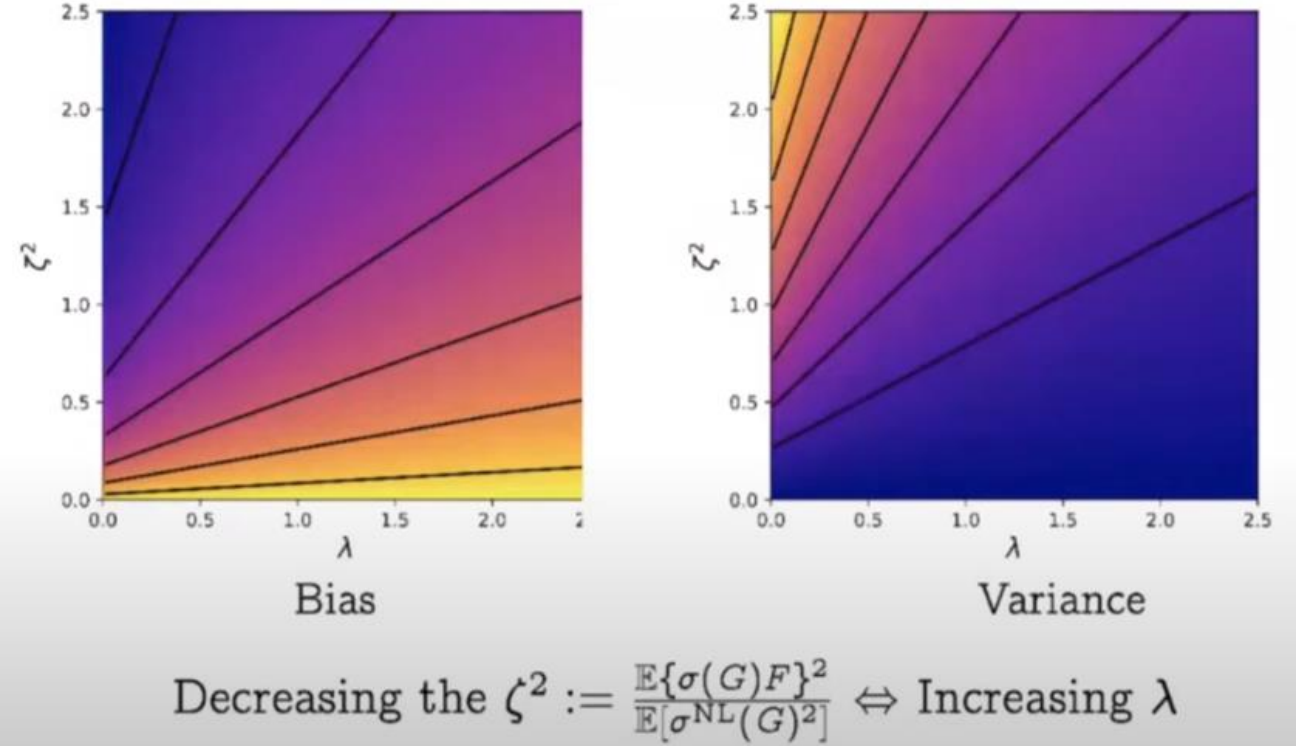


Figure 1. Wavelet transform of an image $x(u)$, computed with a cascade of convolutions with filters over $J = 4$ scales and $K = 4$ orientations. The low-pass and $K = 4$ band-pass filters are shown on the first arrows. (Online version in colour.)

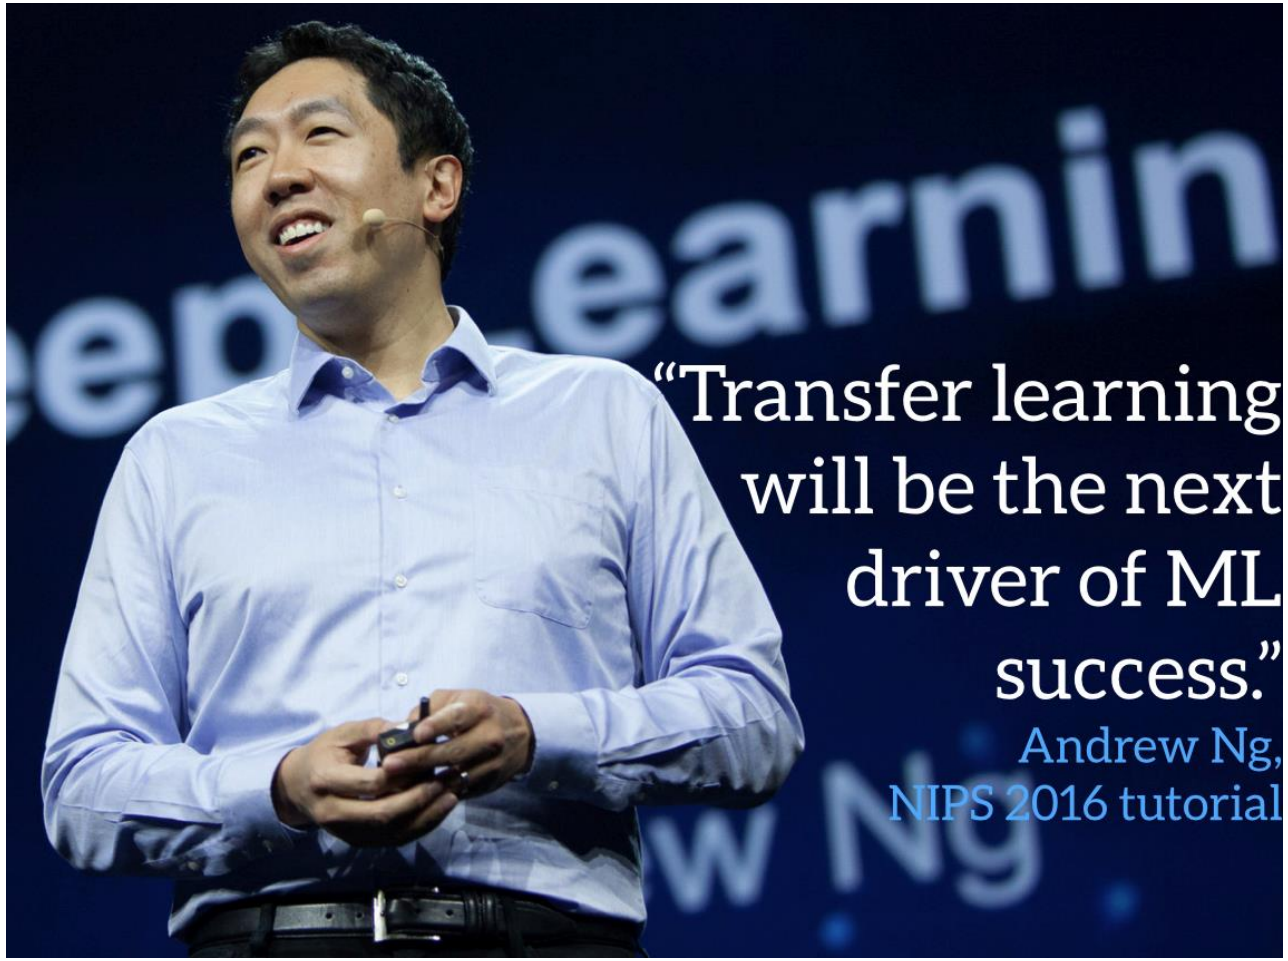
D'OÙ VIENT LA CAPACITÉ DE GÉNÉRALISATION DES DNN

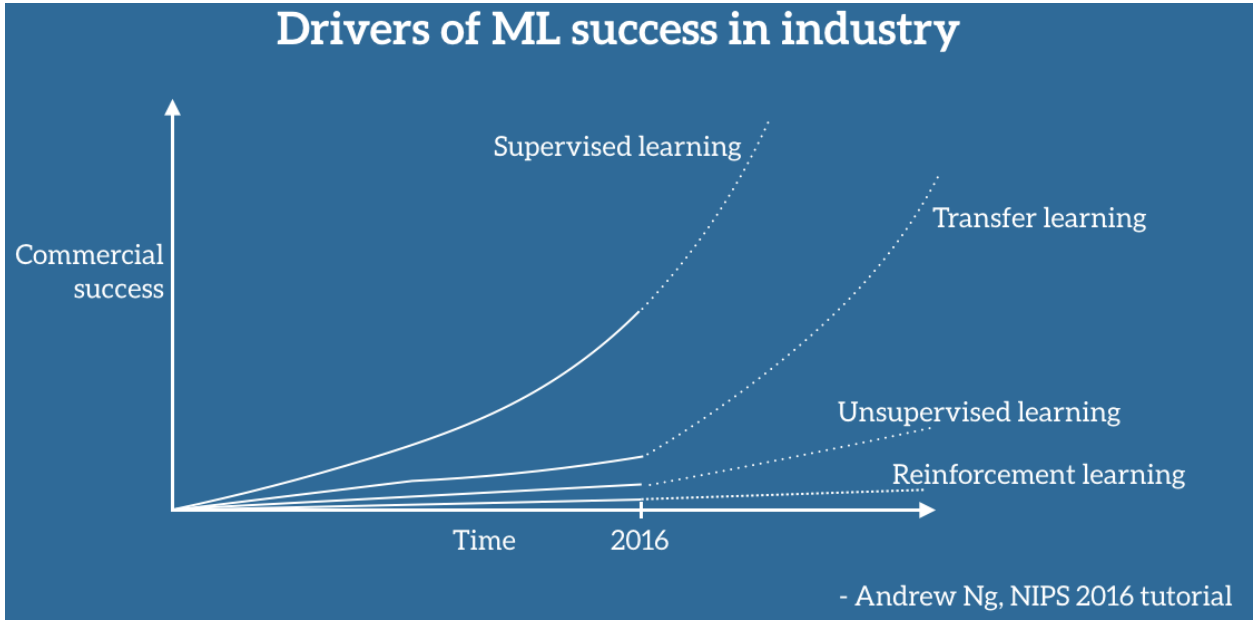
- **Les non-linéarités dans les architectures de réseaux de neurones semblent avoir la même influence en terme de généralisation que la régularisation.**
  - Montanari, Andrea, and Yiqiao Zhong. "The interpolation phase transition in neural networks: Memorization and generalization under lazy training." *arXiv preprint arXiv:2007.12826* (2020).



THÉORIE DES MATRICES ALÉATOIRES ET CONCENTRATION DE LA MESURE

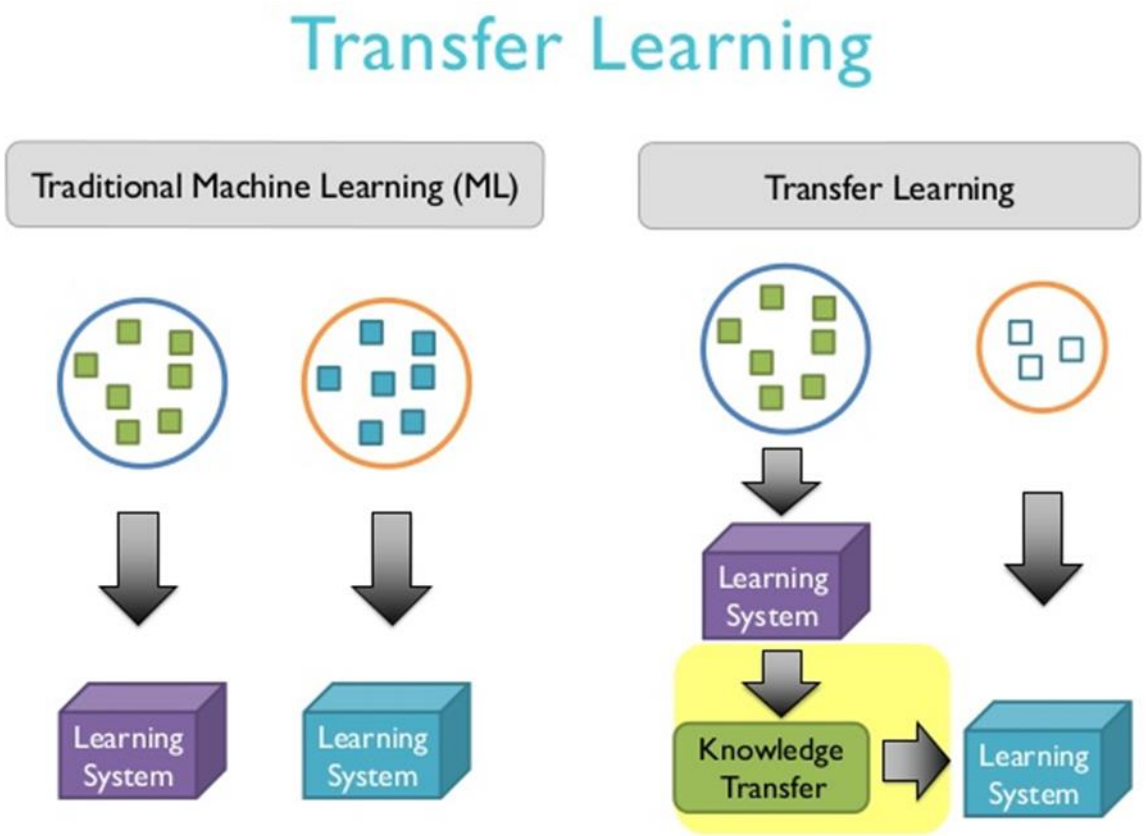
STATISTIQUES EN GRANDE DIMENSION: L'EXEMPLE DU TRANSFER LEARNING





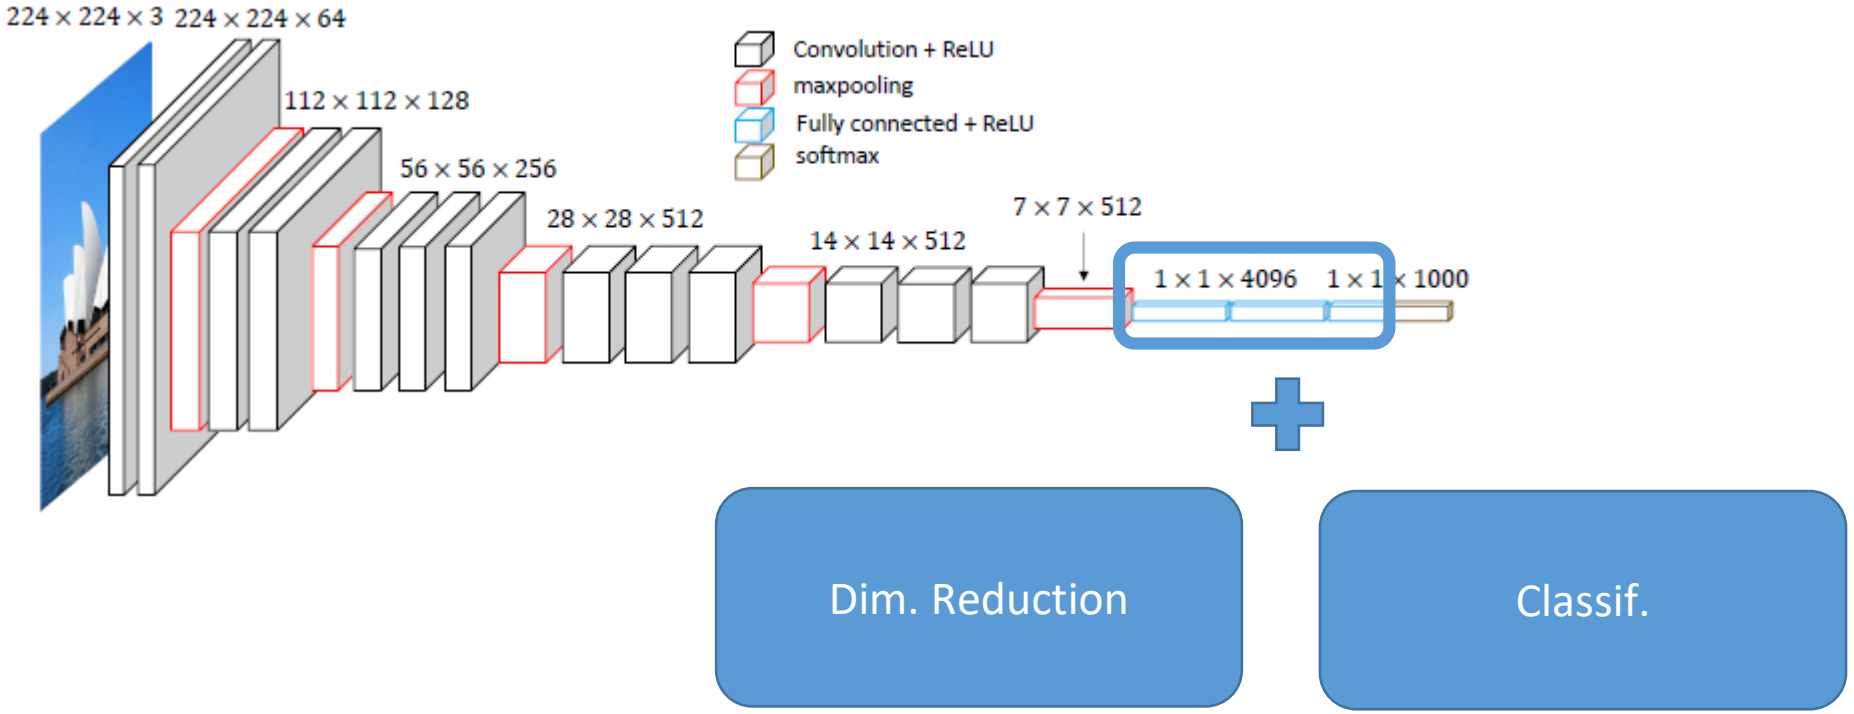
LE PRINCIPE DU TRANSFER LEARNING

- **Sinno Jialin Pan et Qiang Yang, ”A Survey on Transfer Learning”, *IEEE Transactions on Knowledge and Data Engineering*, n°20(10), 2010**



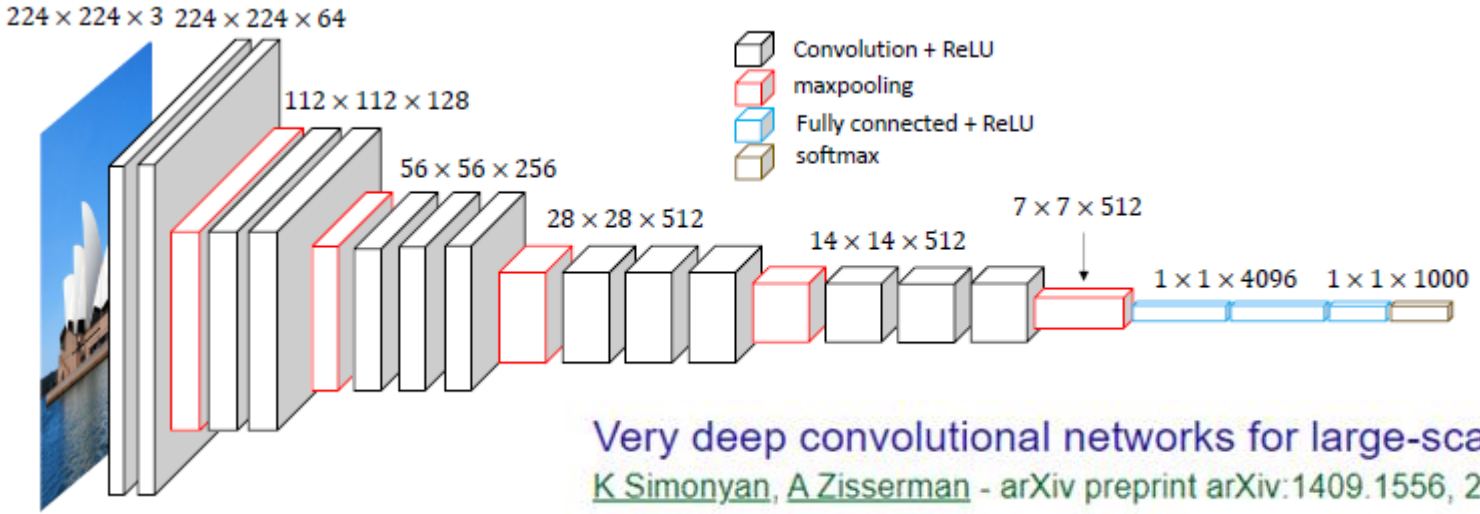
TRANSFER LEARNING EN PRATIQUE

- VGG pré-appris sur ImageNet (1000 classes d'ILSVRC)



TRANSFER LEARNING EN PRATIQUE

- VGG pré-appris sur ImageNet (1000 classes d'ILSVRC)



Very deep convolutional networks for large-scale image recognition

K Simonyan, A Zisserman - arXiv preprint arXiv:1409.1556, 2014 - arxiv.org

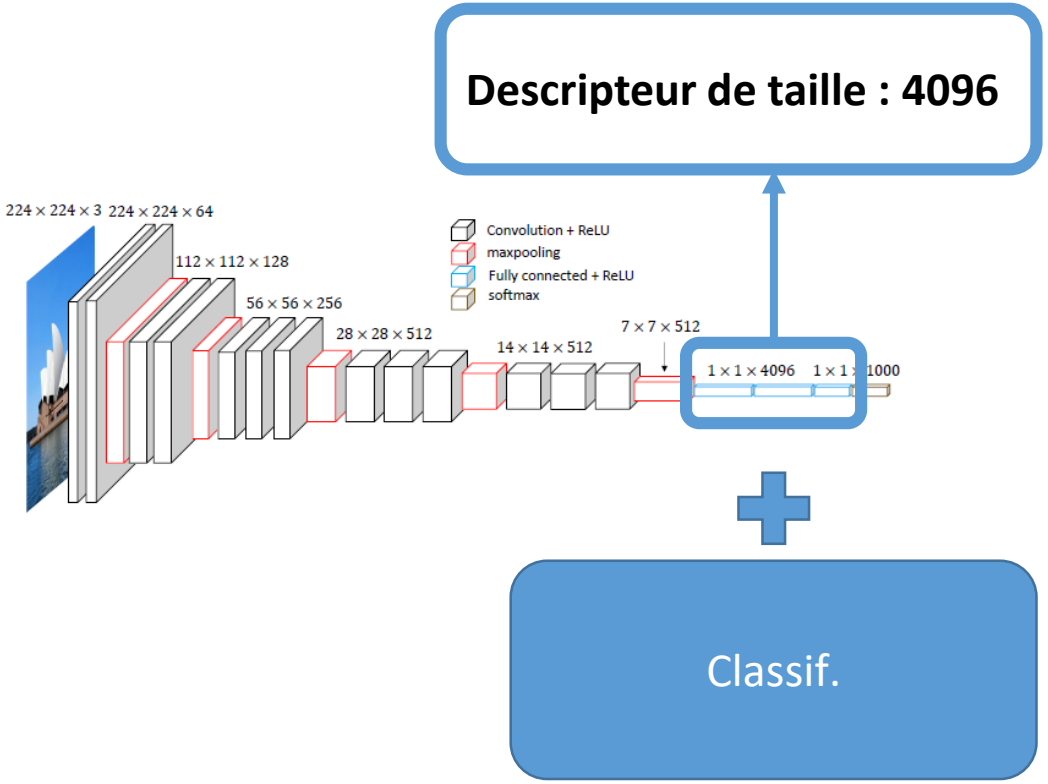
In this work we investigate the effect of the convolutional network depth on its accuracy in the large-scale image recognition setting. Our main contribution is a thorough evaluation of networks of increasing depth using an architecture with very small (3x3) convolution filters, which shows that a significant improvement on the prior-art configurations can be achieved by pushing the depth to 16-19 weight layers. These findings were the basis of our ImageNet Challenge 2014 submission, where our team secured the first and the second places in the ...

☆ 99 Cité 52229 fois Autres articles Les 29 versions Importer dans BibTeX »

TRANSFER LEARNING SUR UN EXEMPLE

- **Caltech-UCSD Birds 200**
  - 200 catégories (espèces d'oiseaux) pour un total de **6033 images**





QUEL EST LE PROBLÈME ?

- Dans ce cas on ne fait plus de Deep Learning. C'est déjà fait pour construire (avec l'architecture VGG) le descripteur de dimension : **4096**

- On fait juste du machine learning :
  - Régression
  - Réduction de dimension
  - Classification
  - Clustering

- On va alors utiliser dans la plupart des cas **la matrice de covariance** (exemple : PCA)

- Qu'est ce qu'il ce passe dans ce cas précis où on a : **n = 6033 données de dimension p = 4096** ?

MATRICE DE COVARIANCE EMPIRIQUE

- Considérons des données $x_1, \dots, x_n$ de dimension p, i.i.d. issues d'une loi normal $\mathcal{N}(0, I_p)$

- La matrice de covariance empirique est donnée par :

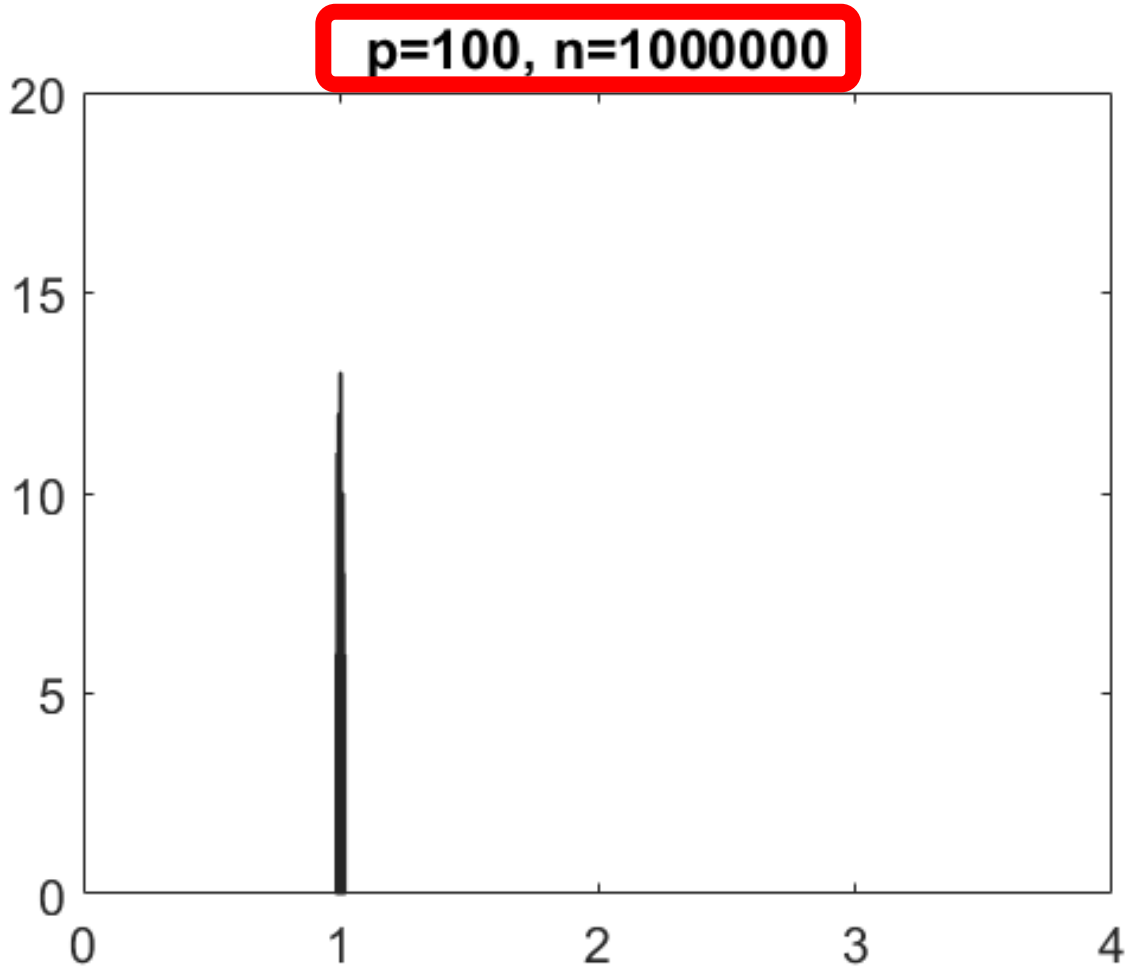
$$C_n = \frac{1}{n}\sum_{i=1}^{n} x_i x_i^T = \frac{1}{n} X X^T \quad \text{Où } X = [x_1, \dots, x_n] \in R^{p \times n}$$

- On s'attend à ce que :

$$\lim_{n \to \infty} C_n = \mathrm{I_p}$$

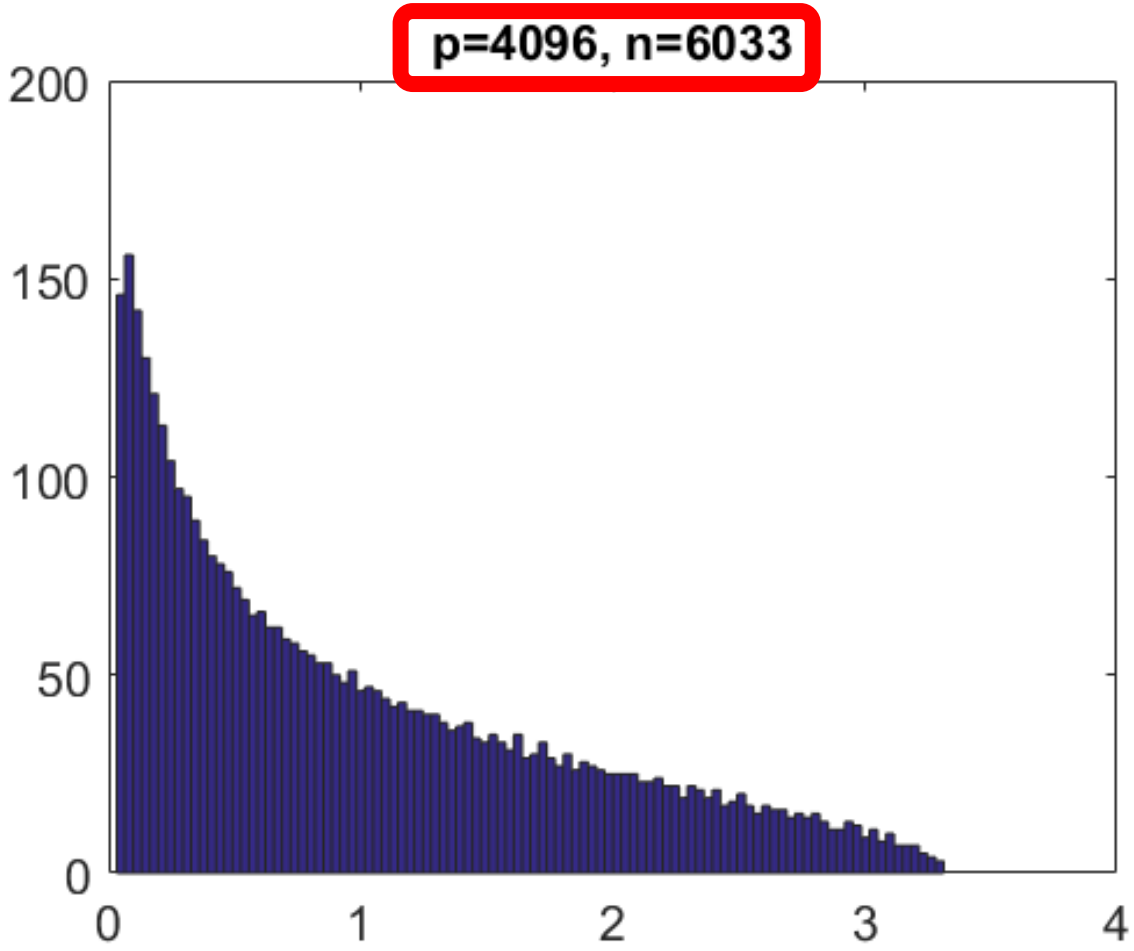
- En gros, **« 1 » est la seule valeur propre de C_n pour n grand.**

HISTOGRAMME DES VALEURS PROPRES DE C_n



HISTOGRAMME DES VALEURS PROPRES DE C_n

- Dans le cas de notre exemple de transfer learning



DANS LE CAS DE LA PCA

- Considérons des données $X = [x_1, \dots, x_n]$ de dimension p, i.i.d. issues d'une loi normal $\mathcal{N}(0, I_p)$

- Soit $\omega \in \mathbb{R}^+$ et u un vecteur unitaire de dimension p.

- Soit

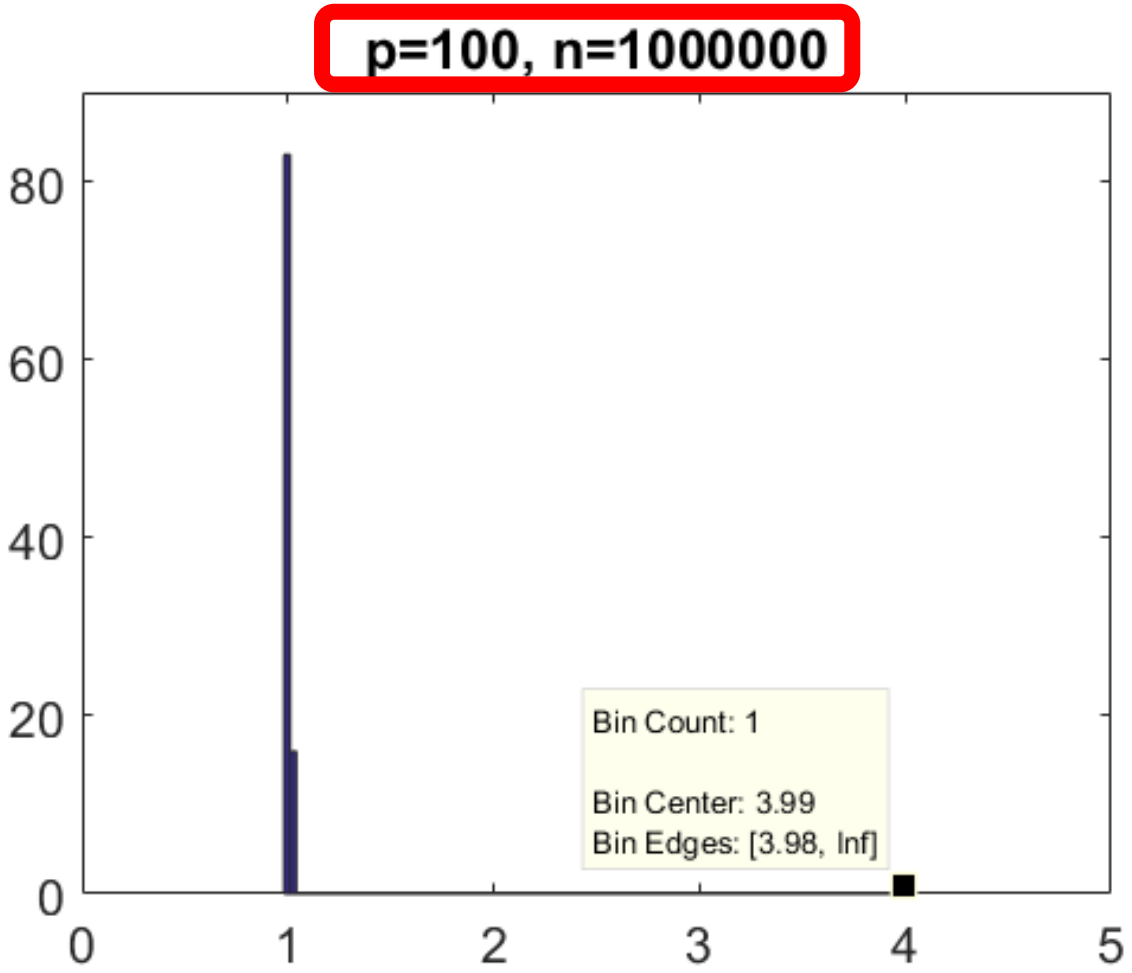
$$Y = \left(I_p + \omega u u^T\right)^{1/2} X$$

- La matrice de covariance empirique associée est :

$$\frac{1}{n} Y Y^T = \left(I_p + \omega u u^T\right)^{1/2} \underbrace{\frac{1}{n} X X^T}_{C_n} \left(I_p + \omega u u^T\right)^{1/2} \xrightarrow[n\to\infty]{} I_p + \omega u u^T$$

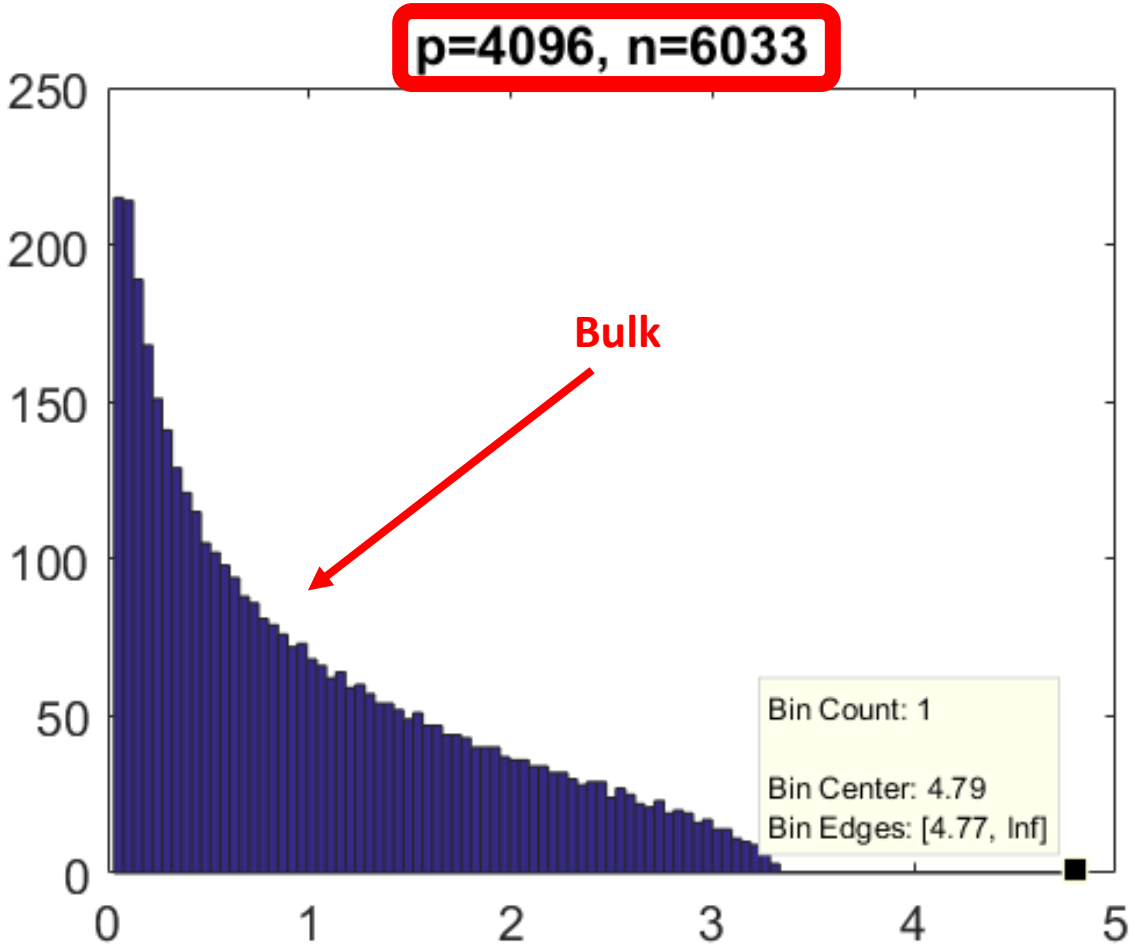
HISTOGRAMME DES VALEURS PROPRES DE C_n

Pour $\omega = 3$



HISTOGRAMME DES VALEURS PROPRES DE C_n

- Dans le cas de notre exemple de transfer learning



QUE NOUS DIT LA THÉORIE DES MATRICES ALÉATOIRES ?

- Théorème de Marchenko-Pastur (1967)
  - Etant donné une matrice $X \in \mathbb{C}^{p\times n}$ dont les entrées sont des variables aléatoires i.i.d. telles que

$$\mathbb{E}(X_{ij}) = 0, \quad \mathbb{E}|X_{ij}|^2 = \sigma^2, \quad \mathbb{E}|X_{ij}|^4 < \infty$$

  - On considère le régime $n, p \to \infty$ et $\frac{p}{n} \to c \in (0, \infty)$.
  - Alors la mesure spectrale de la matrice de covariance satisfait : presque sûrement,

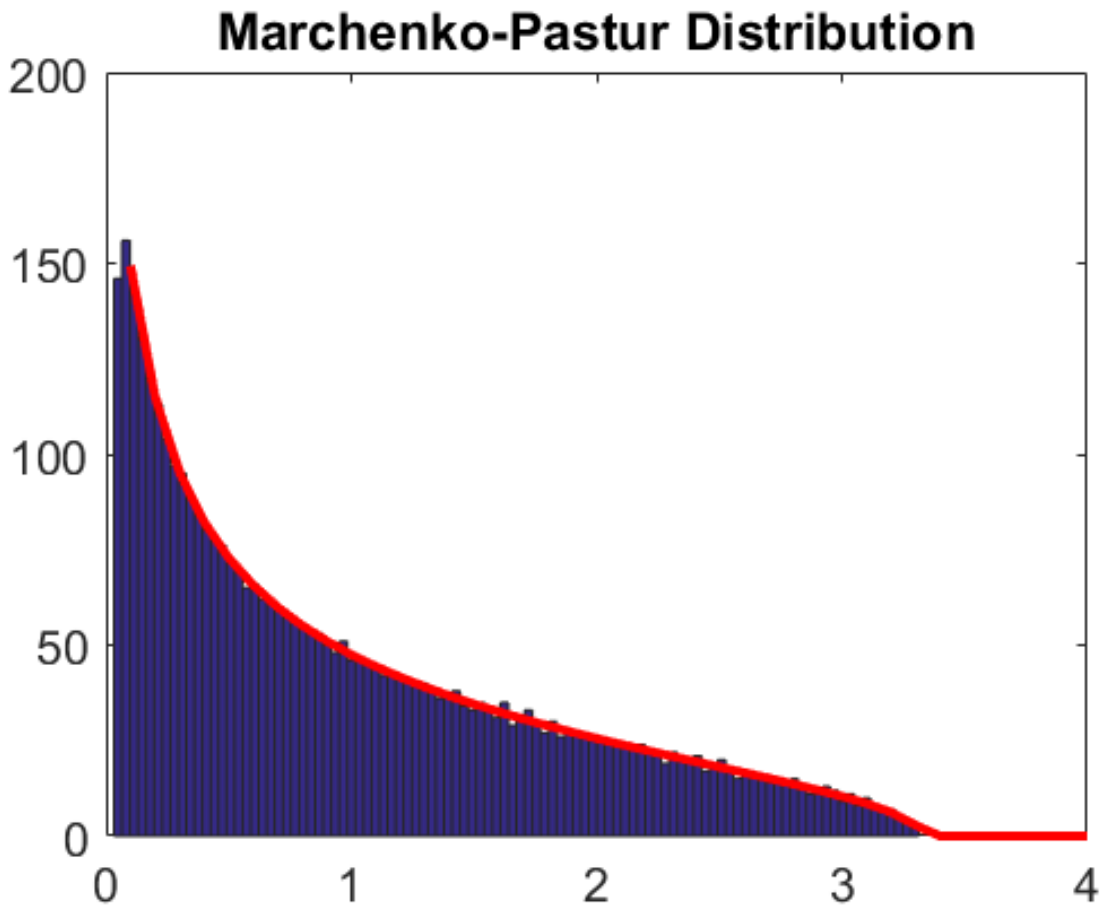
$$L_n = \frac{1}{n}\sum_{i=1}^{n} \delta_{\lambda_i} \to \mathbb{P}_{MP}$$

  - Avec

$$f_{MP}(x) = \frac{\sqrt{(\lambda^+ - x)(x - \lambda^-)}}{2\pi c x} 1_{[\lambda^-, \lambda^+]} \text{ and } \lambda^{\pm} = (1 \pm \sqrt{c})^2$$

QUE NOUS DIT LA THÉORIE DES MATRICES ALÉATOIRES ?

- **Marchenko-Pastur Distribution**



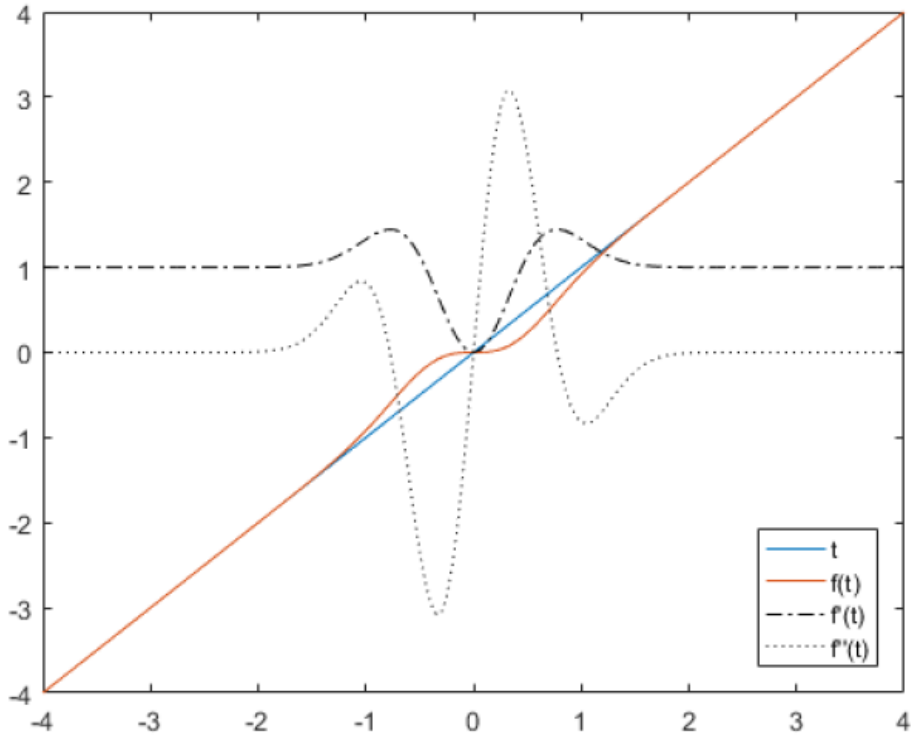
THÉORIE DES MATRICES ALÉATOIRES POUR LA PCA

- Seddik, Mohamed El Amine, Mohamed Tamaazousti, and Romain Couillet. "A kernel random matrix-based approach for sparse PCA." *International Conference on Learning Representations (ICLR)*. 2019.

- Au lieu d'appliquer la PCA à C_n

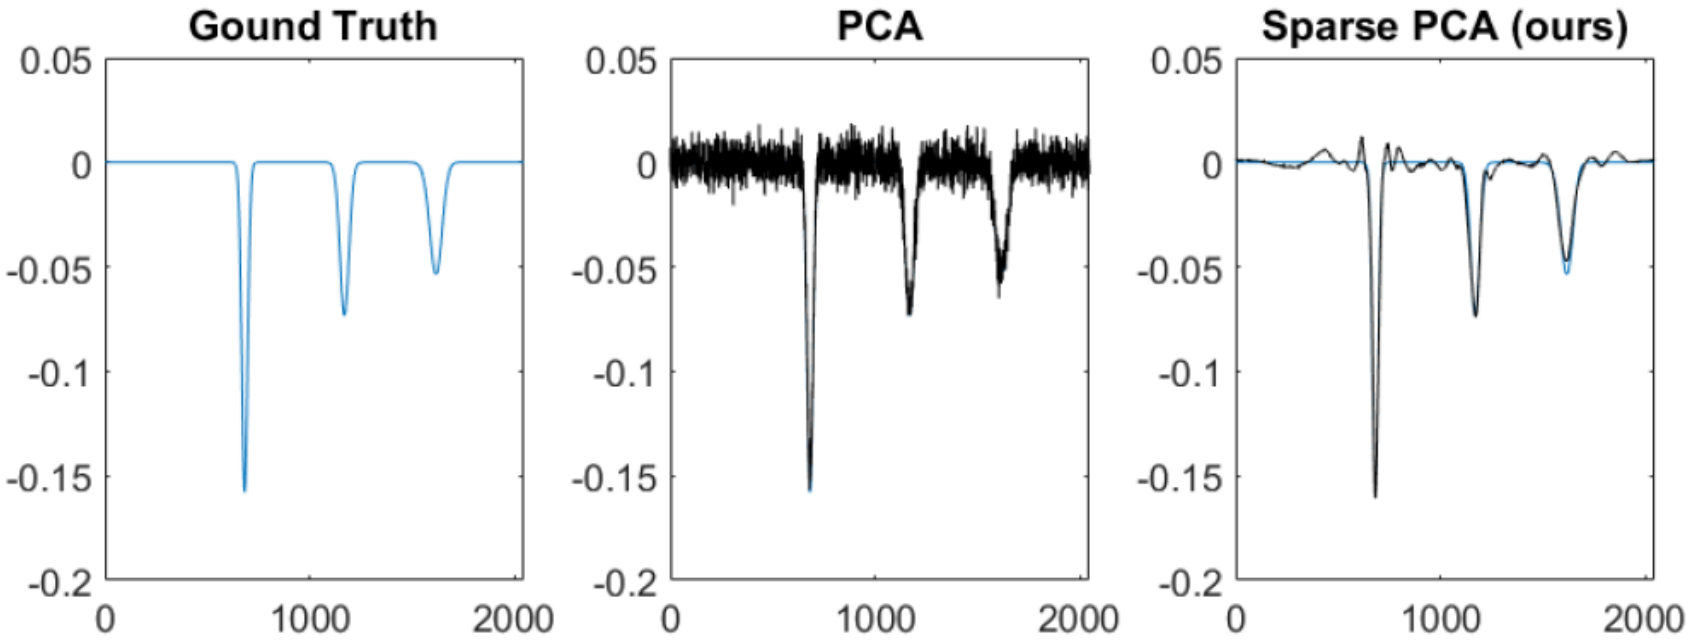
- On l'applique à une déformation $f(C_n)$

$$f(t) = t\left(1 - exp(-t^2)\right)$$



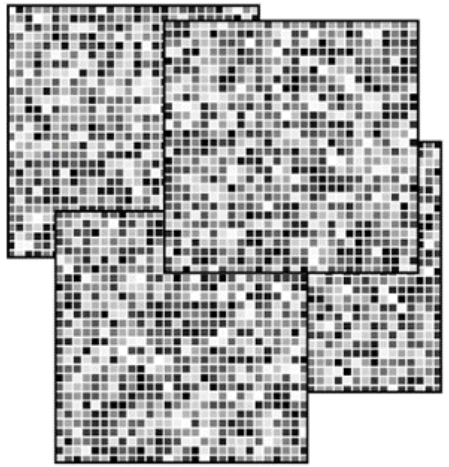
THÉORIE DES MATRICES ALÉATOIRES POUR LA PCA

- **Seddik, Mohamed El Amine, Mohamed Tamaazousti, and Romain Couillet. "A kernel random matrix-based approach for sparse PCA."** ***International Conference on Learning Representations (ICLR)*****. 2019.**



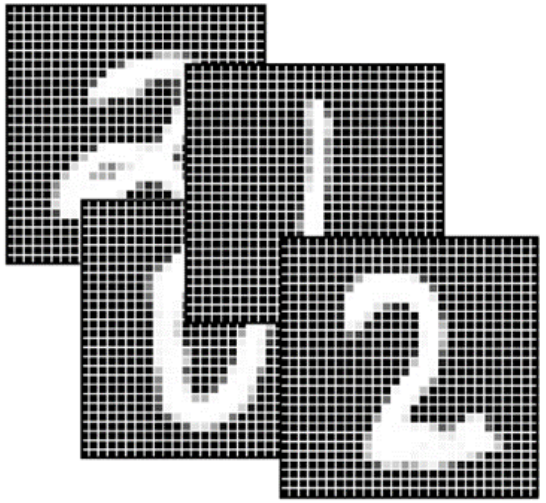
MODÈLE STATISTIQUE DES DONNÉES

Théoricien



Gaussiennes i.i.d.

Expérimentateur



Données réelles

EN RÉSUMÉ

- **La révolution du Deep Learning**
  - Les DNN fournissent souvent les meilleurs résultats (e.g. ImageNet)
  - Ils sont grandement utilisés en pratique

  ➔ on veut naturellement élargir le champs des applications des DNN, mais…
- **Pourquoi chercher à comprendre le Deep Learning ?**
  - Problème 1 : le manque de fiabilité des DNN
    - les exemples adversarials
    - IA de confiance : le besoin est déjà là (véhicule autonome, aide à la chirurgie, applications nucléaires,…)
  - Problème 2 : la consommation et l'usage excessifs du Deep Learning
    - Le choix des hyper-paramètres : beaucoup de cuisine
    - IA frugale : le besoin est déjà là (démocratisation du Deep Learning)
- **Comment est abordée la compréhension du Deep Learning ?**
  - Outils de visualisations : pratique mais sans garantie sur les performances
  - Outils théoriques : des garanties fortes mais sur des sous parties du problème global (ou des versions simplifiés)
    - Théorème d'approximation universel des réseaux de neurones.
    - Mais en pratique, on n'est pas sûr que l'algorithme d'optimisation permet d'obtenir la solution recherchée. Par ailleurs, il faut savoir combien de données sont nécessaires pour l'approximation de la fonction.
    - On ne veut pas fitter les données exactement, alors comment généraliser ? De manière empirique : splitting du dataset en train et test. De manière théorique : la régularisation / l'architecture (la non linéarité agit comme la régularisation)
- **Théorie des matrices aléatoires et Concentration de la mesure**
  - Nécessaire de bien maitriser le passage en grande dimension (statistique en grande dimension, exemple du Transfer Learning)
  - Proposer des modèles statistiques pour les données qui soient plus réalistes que le modèle Gaussien (vers les vecteurs concentrés)