T1 Architecture des processeurs
Introduction

Nicolas Gac

Maître de conférences à l'université Paris Saclay
L2S (Univ. Paris Saclay/CNRS/CentraleSupélec)

** slides de cours rédigés par Alain Mérigot (université-paris-saclay)*

université PARIS-SACLAY

M2 SETI 2022-23

UE T1 architecture avancée

3 ECTS

CM (15h) / TD (4h) / TP (9h)

Intervenants

- Omar Hammami (ENSTA) *omar.hammami@ensta-paris.fr*
- Nicolas Gac (UPSay - L2S) *nicolas.gac@universite-paris-saclay.fr*

Evaluation

Compte rendu TD/TP

TD à rendre pour le 7 novembre	10 %
TP à rendre pour le 5 décembre	20 %

Dépôt en ligne sur e-campus

Examen sur table (avec document)

Jeudi 1er décembre 9h/11h	70 %

Partie 1 - Cours (3h) — **amphi S.A4/S.104**

- C1 (N.Gac) **Introduction** — Amphi S.A4 - *jeudi 29/09 8h45/12h*
- C2 (N.Gac) **Jeux d'instructions** — S.104 - *jeudi 13/10 8h45/12h*
- C3 (N.Gac) **Pipeline** — S.104 - *vendredi 14/10 8h45/12h*

Partie 2 - Cours (1h30) puis TD (2h) — **S.015 + S.201 (G1) et S.211 (G2)**

- C4 (O.Hammami) **Processeurs superscalaires et VLIW** — S.015 - *lundi 17/10 8h45/10h15*
  TD1 (G1 O.Hammami) — *10h30/12h30*
  TD1 (G2 N. Gac) — *jeudi 20/10 8h45/10h45*
- C5 (O.Hammami) **Hiérarchie mémoire** — S.015 - *lundi 24/10 8h45/10h15*
  TD2 (G1 O.Hammami/G2 N. Gac) — *10h30/12h30*
- C6 (O.Hammami) **Optimisations logicielles** — S.015 - *lundi 31/10 8h45/10h45*
  Séminaire — S.015 - *11h/12h*

Partie 3 - TP (3h) — **S.201 (G1) et S.210 (G2)**

G1	TP1 (O.Hammami) **Analyse de performances**	lundi 31/10 13h45/17h
	TP2 (O.Hammami) **Simulateur de processeur MIPS**	lundi 07/11 8h45/12h
	TP3 (N.Gac) **Simulation de cache de données et TLB**	mardi 15/11 13h45/17h
G2	TP1 (N.Gac) **Analyse de performances**	jeudi 10/11 8h45/12h
	TP2 (N.Gac) **Simulateur de processeur MIPS**	mardi 15/11 8h45/12h
	TP3 (N.Gac) **Simulation de cache de données et TLB**	jeudi 17/11 8h45/12h

Brève histoire des ordinateurs (cont.)
Premiers calculateurs électroniques 1940–1950

Caractéristiques de l'EDVAC
1000 mots de 44 bits (5ko)
6000 tubes
56kW,
1.16 kHz
8 tonnes, 45m^2
MTBF[1] 8h



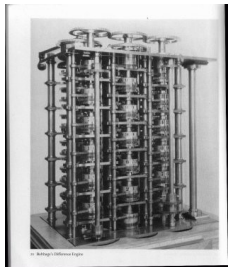
[1] *Mean Time Between Failure*

Brève histoire des ordinateurs
Les pionniers



- Blaise Pascal (1623–1662)
  1642 *Pascaline*
  Première calculatrice mécanique

- Gottfried Leibnitz (1646–1716)
  1670 Ajout des opérations de multiplication et division



- Charles Babbage (1791–1871)
  et Ada Lovelace (1815–1852)
  1850 La machine analytique :
  Première machine programmable

Brève histoire des ordinateurs (cont.)
Ère des calculateurs à semi-conducteurs 1950-1970

1947 Invention du transistor (John Bardeen (1908–1991) et William Shockley (1910–1989)) (Bell Labs)

Apparition des premiers ordinateurs commerciaux (IBM, Digital, CDC, Honeywell, etc)

Premiers systèmes d'exploitation Multiprogrammation

Premiers compilateurs (Fortran, John Bacchus 1959)

Premiers multiprocesseurs



Mini ordinateur PDP-8 (Digital Equipment)

Brève histoire des ordinateurs (cont.)
Premiers calculateurs électroniques 1940–1950

- 1943 : la *bombe* Alan Turing (1912–1954) & Gordon Welchman (1906–1985) (cryptographie) [électromécanique]
- 1944 : Colossus Max Newman (1897–1984) & Tommy Flowers (1905–1998) (cryptographie) [tubes]
- 1944 : Mark I (Harvard) Howard Aiken (1900-1973) [électromécanique] 1 addition/s
- 1946 ENIAC John Mauchly (1907–1980) et John-Presper Eckert (1919–1995) (Un. Penn.)
  Entièrement électronique [tubes]
  1 multiplication 2.2 s
- 1947 EDVAC Mauchly, Eckert et John von Neumann (1903–1957) (U. Penn.)
  Premier ordinateur moderne
  Calcul en binaire
  Programme enregistré en mémoire (*machine de von Neumann*)
- 1949 Manchester Mark-I Max Newman (Un. Manchester)
  (premier ordinateur commercialisé Ferranti Mark-I)

Brève histoire des ordinateurs (cont.)

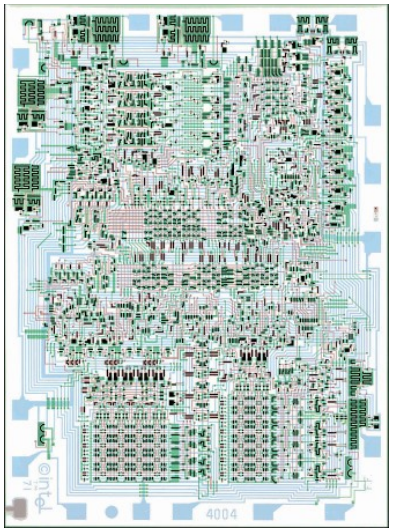
Apparition des circuits intégrés 1970–1980

1970 4004
premier microprocesseur :
processeur 4 bits,
2300 transistors

1972 8008
premier processeur 8 bits
3500 trans. 300 kHz
premier microordinateur Micral (R2E)
2ko RAM 1973

1974 8080
processeur 8 bits 4500 transistors, 2MHz

1978 8086
premier processeur 16 bits
29ktrans. Utilisé dans les premiers PC



Le processeur 4004 d'Intel

Brève histoire des ordinateurs (cont.)

Ère des processeurs intégrés 1980+

1980-1990 Processeurs pipeline, processeurs de calcul flottant, caches, ...

1990-2000 Parallélisme d'instruction (superscalaire et VLIW), exécution spéculative, parallélisme de données (SIMD), ...

2000-2010 Parallélisme de thread, multicoeurs

2010+ *system-on-chip* (SoC)

Les grandes classes de systèmes informatiques

Ordinateurs personnels

- Ordinateurs de bureau
- Ordinateurs portables

Serveurs de calcul ou de stockage

- *Supercomputers*
- *Data centers* (*cloud computing*)

Systèmes embarqués
Embedded systems (informatique enfouie)

Les grandes classes de systèmes informatiques (cont.)

Les systèmes embarqués



Evolution des performances des processeurs

Liés à de nombreux facteurs

- Amélioration de la technologie
  - augmentation du nombre de transistors/circuit
  - réduction du temps de traversée
  - diminution de la consommation d'un transistor
- Améliorations architecturales
- Améliorations logicielles (compilateurs)
- Demandes du marché et contraintes économiques

Les grandes classes de systèmes informatiques (cont.)

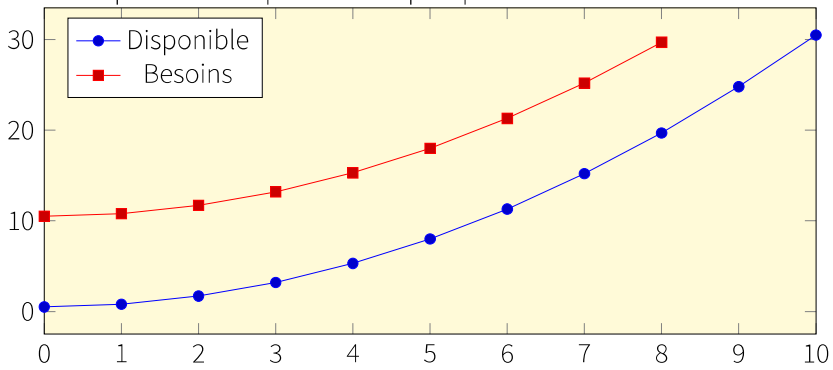
	Ordinateur de bureau	Serveur	Système embarqué
Prix	100–1000$/proc.	200–2000$/proc.	0.1–200$/proc.
Ventes mondiales (2013)	300 M	10 M	15 G
Critères	Rapport prix/performance. Graphique	Performances, débit, disponibilité, évolutivité	Prix, consommation, performance pour l'application

Aspect économiques et applicatifs

Des besoins croissants

Modèle économique piloté par la technologie (Intel)

De nombreuses applications nécessitent toujours plus de puissance de calcul (serveurs, ordinateurs personnels, embarqué haut de gamme).
Il suffit de produire des processeurs plus puissants et le marché suivra.



Les grandes classes de systèmes informatiques (cont.)

Haut de gamme

Processeurs des PC et serveurs

Spécialisé

Haut de gamme des générations précédentes.

Ex : MIPS, PowerPC

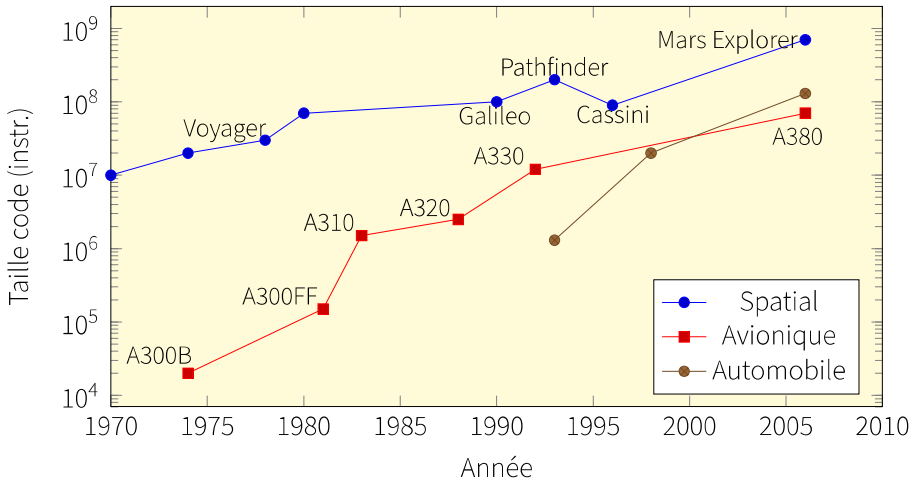
Embarqué

Faible consommation, temps réel.

Contraintes
- Prix
- Performance
- Encombrement
- Consommation
- Temps réel

Aspect économiques et applicatifs (cont.)

Des logiciels embarqués de plus en plus complexes



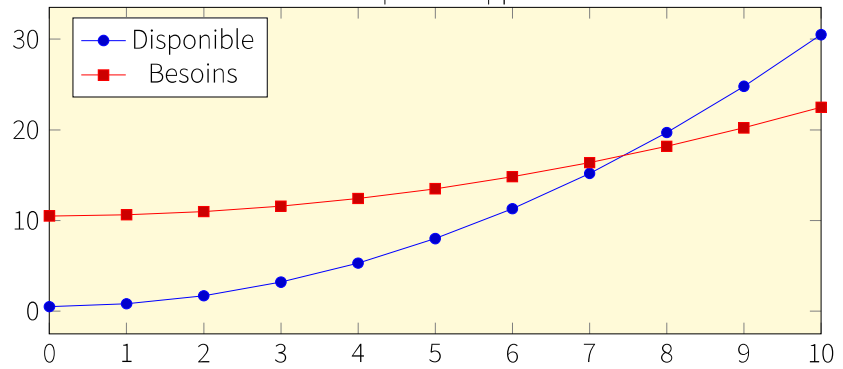
firefox=10M, linux kernel+drivers=15M, windows 10 60M, google 2G

Aspect économiques et applicatifs (cont.)

Créer de nouveaux besoins

Modèle économique piloté par les applications

Cas où les performances sont supérieures aux besoins (comme un certain nombre d'applications embarquées).
Il faut créer de nouveaux besoins par des applications.

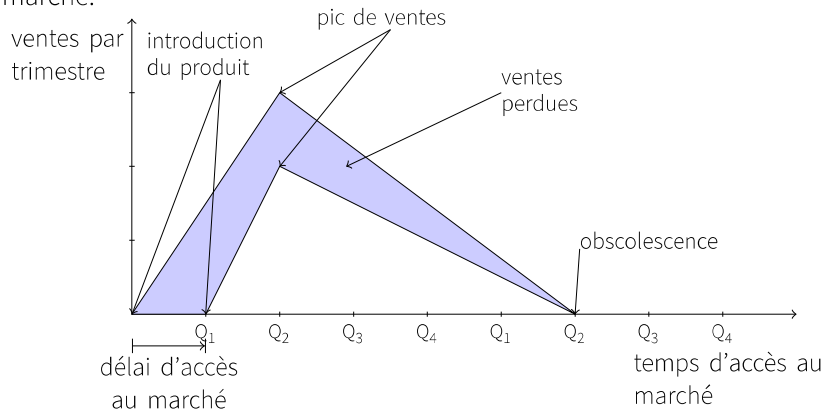


Recherche de la *killer application*

Aspect économiques et applicatifs (cont.)

Temps d'accès au marché

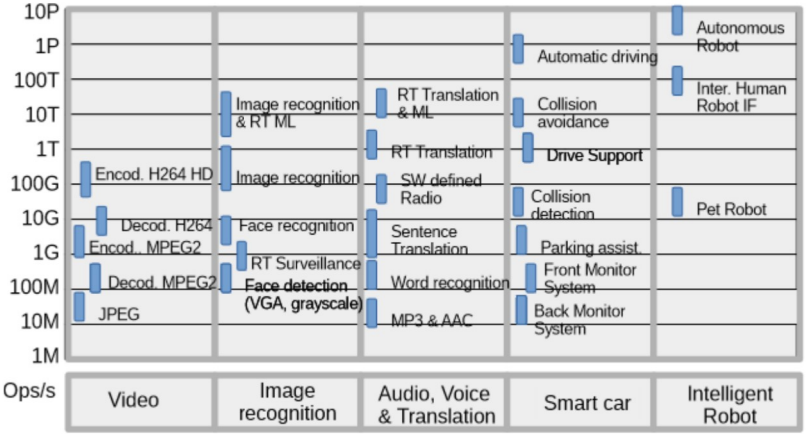
Obsolescence très rapide du matériel (18 mois) : il faut être le premier sur le marché.



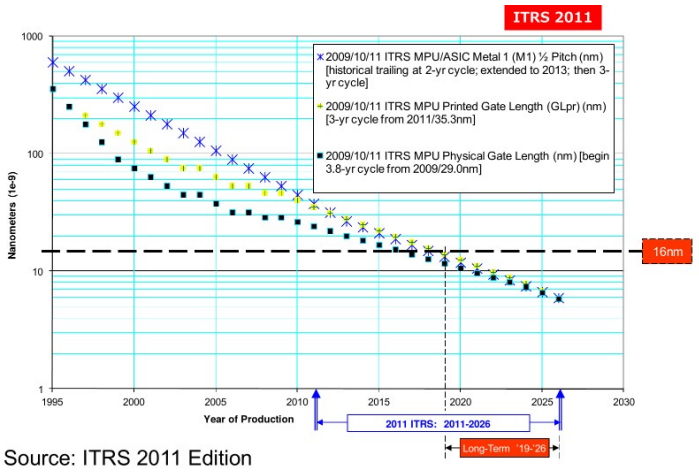
Un délai d'introduction d'un produit entraîne une perte de ventes.
time-to-market

Aspect économiques et applicatifs (cont.)

Prévisions de charge sur les applications embarquées



Les grandes tendances de la technologie (cont.)
Loi de Moore



Source: ITRS 2011 Edition

Dimensionnement des transistors

Les grandes tendances de la technologie
Loi de Moore

- Dimensions technologiques réduites de 16%/an
  - Densité de transistors X 1.35/an
- Augmentation de la taille des circuits de 5 à 10%/an

→ Le nombre de transistors/circuit croit de 40 à 45%/par an (×2 tous les 22 à 24 mois)
Loi de Moore (Gordon Moore, né en 1929) [1965/1975]

Pour les mémoires l'augmentation est similaire, mais se réduit :

- ×4 tous les 3 ans dans les années 90
- ×2 tous les ans dans les années 2000
- ×2 tous les 2 à 3 ans actuellement

Les grandes tendances de la technologie (cont.)
Loi de Moore

MAIS....

Maille de silicium : 0,543nm

Actuellement (2021) gravure 10nm à 5nm : un canal fait de 20 atomes (10nm) à 10 atomes (5nm) !

Nombreux problèmes de gravure, fiabilité, dispersion lors du dopage (10^{-2} – 10^{-5}), effet tunnel, etc

Limites physiques de l'effet transistor en dessous de 2–3 nm.

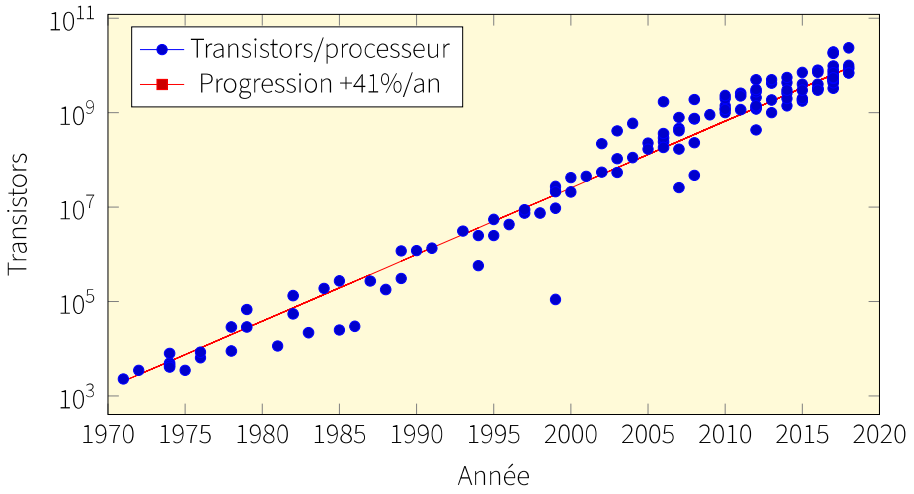
Fin de la loi de Moore dans quelques années (≈2025)[2] .

(sauf rupture technologique)

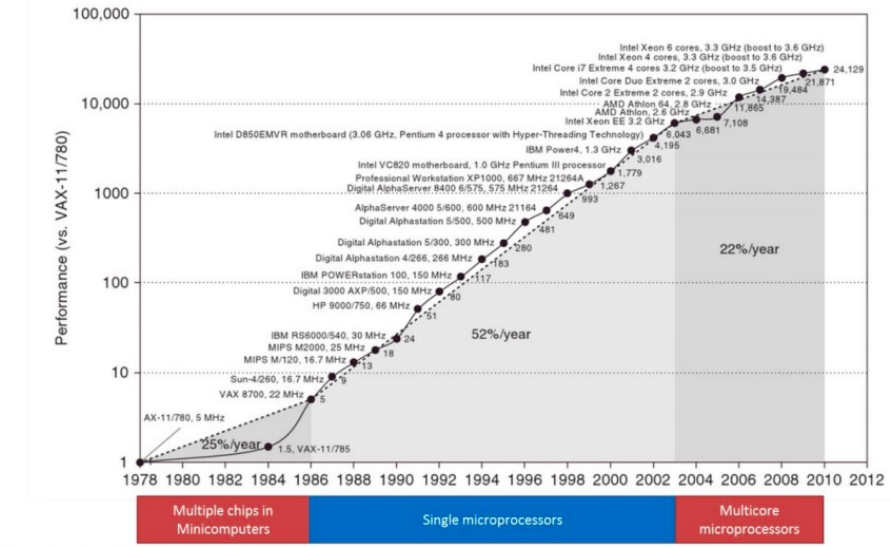
[2] Intel a annoncé 18 Ångströms fin 2025.

Les grandes tendances de la technologie (cont.)
Loi de Moore

Nombre de transistors/processeur



Les grandes tendances de la technologie (cont.)
Performances des processeurs



Source: Computer Architecture, A Quantitative Approach by Hennessy and Patterson

Les grandes tendances de la technologie (cont.)
Loi de Rock

Loi de Rock (Arthur Rock né en 1926) (ou seconde loi de Moore)

« *Le coût d'une usine de fabrication de circuits semiconducteurs*[3] *double tous les 4 ans.* »

Augmentation exponentielle des coûts de fabrication

Actuellement ≈ 15G$/usine

[3] parfois appelée « fonderie de silicium »

Les grandes tendances de la technologie (cont.)
Performances des processeurs

Jusqu'en 2000, augmentation systématique des performances de 50%/an

Il suffisait d'attendre les améliorations technologiques pour avoir un programme plus rapide.

The free lunch is over (Herb Sutter 2005)

Les grandes tendances de la technologie (cont.)
Impact de l'architecture

L'évolution de performance des processeurs est la combinaison du progrès technologique et des améliorations architecturales.

$$t_e = n_i \times \overline{\text{CPI}} \times T_c$$

(formule de Hennessy-Patterson)[4]

t_e temps d'exécution d'un programme

n_i nombre d'instructions exécutées

$\overline{\text{CPI}}$ nombre moyen de cycles par instruction

T_c temps de cycle

A la fin du XXe siècle amélioration globale des performances de près de 50%/an.

MAIS...

[4] John Hennessy, né en 1952 et David Patterson, né en 1947.

Les grandes tendances de la technologie (cont.)

Performances des processeurs

L'amélioration technologique permettait l'amélioration des performances :

- en augmentant la fréquence des processeurs grâce à des transistors plus petits
- en améliorant les architectures des processeurs grâce à un nombre plus important de transistors :
  - pipeline,
  - exécution dans le désordre, parallélisme d'instruction (superscalaires, VLIW),
  - exécution spéculative,
  - élargissement des chemins de données : 8 bits, puis 16, 32, 64 (et même 128 à 512 bits en parallélisme de données),
  - parallélisme de données (SIMD)
  - *multithreading*
  - ajout de caches L1, puis L2, et L3 dans les processeurs
  - etc

Les grandes tendances de la technologie (cont.)

Historique CPU Intel

Evolution des CPU Intel

Proc.	ann.	Taille/fréq./CPI	innovations
4004	1971	2300tr. / 0.75MHz / ≈10CPI[5]	Premier μprocesseur 4 bits
8080	1974	4500tr. / 2MHz / 4–11CPI	Premier μprocesseur 8 bits
8086	1978	29000tr. / 5MHz / 2–20CPI	Premier μprocesseur 16 bits (code partiellement compatible), mémoire segmentée
80286	1982	135ktr. / 6MHz / 2–20CPI	unité de gestion mémoire (MMU), bus adresses/données non multiplexés, multiplieur entier cablé
80386	1985	275 ktr. /12MHz / 3–10CPI	Processeur 32 bits (bus, registres, ALU), cache L1 externe, mémoire paginée (jusqu'à 4GB)

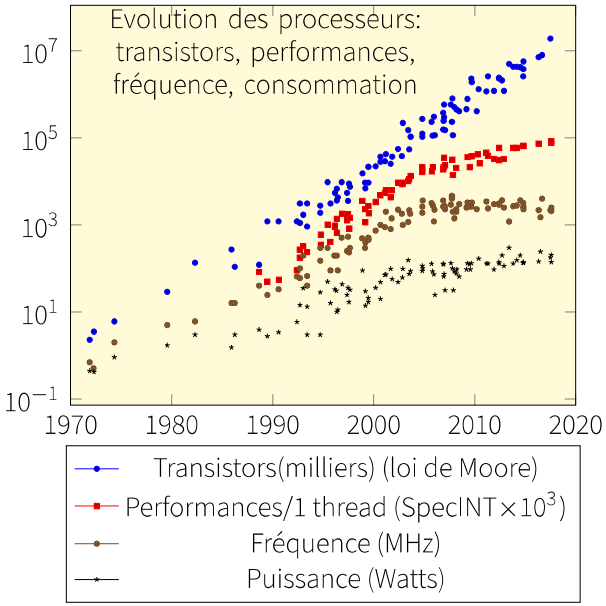
[5] CPI : cycles par instruction

Les grandes tendances de la technologie (cont.)

Proc.	ann.	Taille/fréq./ipc	innovations
80486	1989	1Mtr. /50MHz / 40MIPS[6]	Pipeline, cache L1 intégré (unifié), opérateurs flottants intégrés
Pentium (P5)	1993	3Mtr. / 60MHz / 100 MIPS	Superscalaire (2 instr.), bus 64 bits, cache L1 séparé I/D, prédiction branchement
Pentium MMX	1995	4.5Mtr. / 150MHz	Instructions "multimedia" MMX
Pentium Pro (P6)	1996	5.5Mtr. / 250MHz / 180 MIPS	Exécution dans le désordre, exécution spéculative, coeur RISC
Pentium III	1999	29 Mtr. / 700MHz /400 MIPS	Ext. SSE (*Coppermine* 1999), cache L2 intégré
Pentium 4	2000	40–200 Mtr. / 1.5–3GHz	Pipeline profond, cache μops, SSE2 (*willamette* 2000), SSE3, *hyperthreading* (*Prescott* 2004)
Pentium *core*	2008	1 Gtr.+ / 1.5–3GHz	Multicoeur, L3 intégré, x86-64, AVX (*Nehalem* 2008, *Sandy Bridge* 2011, *skylake* 2015, *coffee-lake* 2018, *icelake* 2019, *tigerlake* 2020)

[6] MIPS : *Million instructions per second*

Les grandes tendances de la technologie (cont.)



Depuis ≈ 2005, stagnation des performances des processeurs individuels

- performance/cycle (un seul thread)
- fréquence d'horloge
- puissance consommée

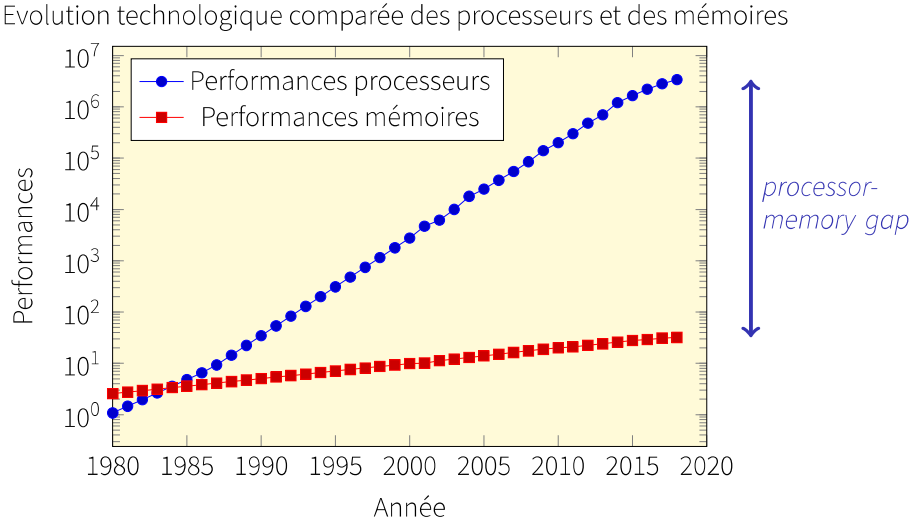
Les grandes tendances de la technologie (cont.)

Il s'avère que :

- l'augmentation de fréquence se heurte au problème de la consommation. Doubler la fréquence revient à quadrupler la consommation (à cause de l'augmentation de tension qui accroit le courant de fuite des transistors). (**power wall**)
- il n'y a plus beaucoup de progrès architecturaux exploitables sur un processeur (**ILP wall**)[7]
- la différence entre performances des mémoires et des processeurs ne fait que s'accroitre (**memory wall**)

[7] ILP : *Instruction level parallelism*

Les *murs* de l'architecture : *Memory wall*



Les *murs* de l'architecture : *Memory wall*

Lors de l'amélioration de la technologie, on va chercher à **augmenter** la taille des mémoires.

Cette augmentation de taille compense en grande partie l'accération obtenue par le progrès technologique.

L'accès mémoire nécessite de 50 à 200 cy sur un processeur actuel...

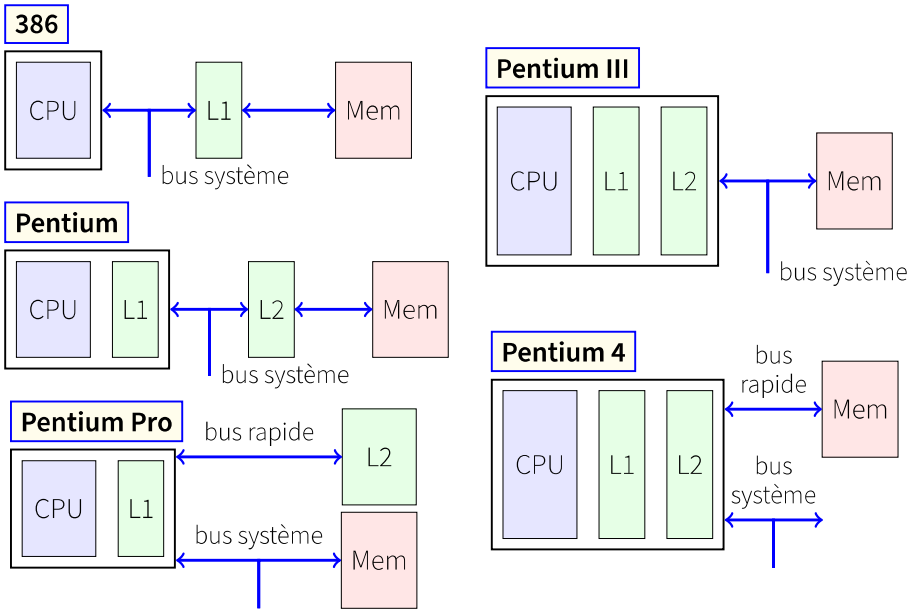
On peut faire :

- des mémoires de grande taille lentes
- des mémoires de petite taille rapides

→ mémoire cache

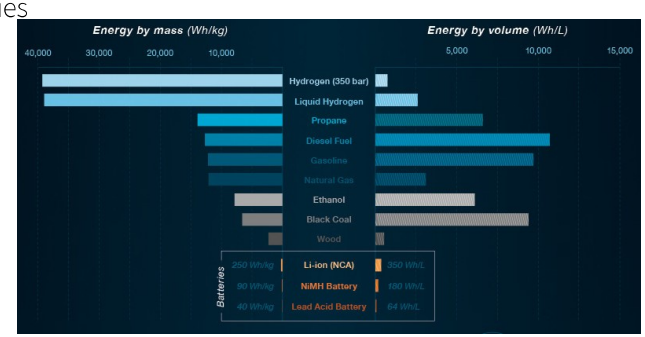
Complexité croissante de la hiérarchie mémoire : caches L1, L2, L3, mémoire principale

Les *murs* de l'architecture : *Memory wall*



Les *murs* de l'architecture : *Power wall* (cont.)

Les batteries

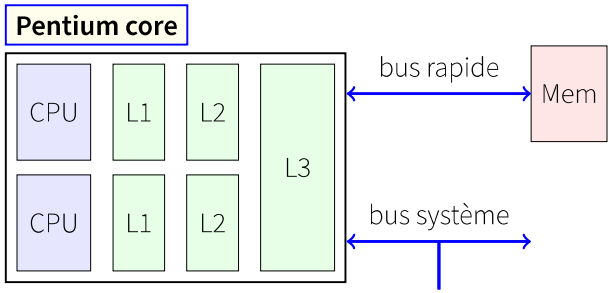


1950 : 40 Wh/kg (Plomb acide)
1978(concept)/1992(commercialisation) : 90 Wh/kg, (Lithium-Ion)
2000 : 140 à 160 Wh/kg . (Lithium-Polymère)
2002 : 190 à 250 Wh/kg (Lithium-Ion-NiCoAl)
2013 (lithium-air) : 1700 - 2400 Wh/kg (expérimental)

Essence : 14000 Wh/kg

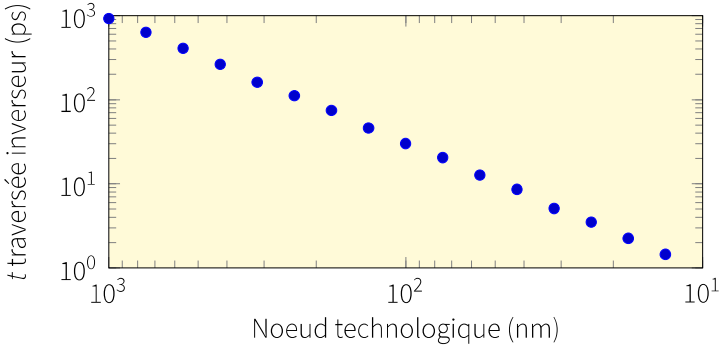
Les *murs* de l'architecture : *Memory wall* (cont.)

La hiérarchie mémoire est un point très critique dans les processeurs actuels



Les *murs* de l'architecture : *Power wall* (cont.)

L'évolution de la technologie entraîne une amélioration des temps de traversée des portes.



Réduction du temps de traversée des portes, mais l'augmentation de fréquence de fonctionnement est limitée par la consommation (et les problèmes de synchronisation à très haute fréquence).

Les *murs* de l'architecture : *Power wall*

La puissance consommée est un problème majeur dans plusieurs applications :

- équipements nomades
- *data-centers* (4% de l'énergie électrique produite aux USA en 2013, 20% de croissance/an)
- objets connectés

Impact

- technologique
- microarchitecture/circuit logique
- architecture
- algorithmique
- système

Les *murs* de l'architecture : *Power wall* (cont.)

Puissance consommée dans un circuit synchrone

$$P \approx \frac{C \times V^2}{T}$$

C capacité totale à commuter, V tension d'alimentation, T période d'horloge.
Amélioration de la technologie: $\rightarrow$ Toutes les dimensions $\times\alpha$ ($\alpha < 1$)
(réduction des dimensions)

Impact sur la capacite C

- $C = n_{\text{portes}} \times C_{\text{porte}}$
- $n_{\text{portes}} = \frac{\text{surf. circuit}}{\text{surf. porte}}$ (surf. circuit $\approx$ cst, surf. porte $\times\alpha^2$)
  $\rightarrow n_{\text{portes}}/\alpha^2$ (nombre de portes $\nearrow$)
- $C_{\text{porte}} \approx S/e$ (transistor ou interconnexions $\equiv$ capacité plane)
  $C_{\text{porte}} \rightarrow C_{\text{porte}} \times \alpha^2/\alpha = C_{\text{porte}} \times \alpha$ (capacité par porte $\searrow$)
- $C \rightarrow C' = C/\alpha$ (capacité totale $\nearrow$)

augmentation de la capacité totale

Les *murs* de l'architecture : *Power wall* (cont.)

Impact sur la période d'horloge

Liée au plus grand temps de traversée de portes entre deux fronts d'horloge. (chemin critique)
Pour une architecture donnée, T est :

- $1/\alpha$ courant dans les transistors ($\nearrow$)
- α capacité d'une porte ou interconnexion ($\searrow$)
- α délais RC de propagation ($\searrow$)

$T \rightarrow T' = T \times \alpha$ (période horloge $\nearrow$)

D'où la puissance $P' = C' \times V^2/T' = P/\alpha^2$
Augmentation quadratique de la puissance avec α !
Technologie améliorée d'un facteur 2 $\Longrightarrow$ Puissance multipliée par 4 !!!!
(à V constant)
Actuellement, un CPU d'un ordinateur de bureau consomme 40 W. Un GPU peut atteindre 200 W.

Les *murs* de l'architecture : *Power wall* (cont.)

- *Tension et courant doivent être proportionnels aux dimensions d'un transistor*
- *Ainsi dimensions* $\searrow \Longrightarrow$ *V et I* $\searrow$
- *Garanti puissance/unité de surface constante*

Partiellement appliquée pour limiter la puissance consommée
Mais réduit les performances $f \approx V^2$

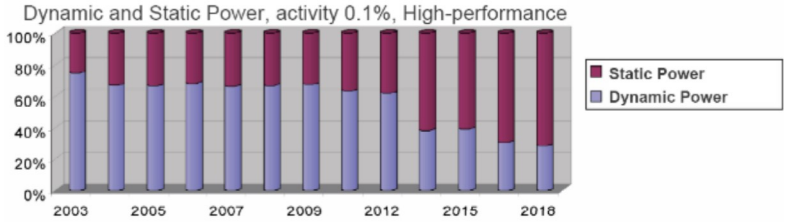
De plus la loi de Dennard ignore :

- l'existence d'une tension de seuil (atteinte)
  Alimentation actuelle $\approx 0.3 - 0.7$V
  Nombreux problème pour réduction additionnelle
- les courants de fuite

Les *murs* de l'architecture : *Power wall* (cont.)

Les courants de fuite. *subtreshold leakage*

Avec la réduction des dimensions technologiques, il y un courant de fuite même pour un transistor qui ne conduit pas.



Les *murs* de l'architecture : *Power wall* (cont.)

parallélisme et puissance consommée

Une des meilleures solutions pour réduire la consommation est le *parallélisme*.

Supposons que l'on ait certaines performances sur un processeur.

Utilisation de deux processeurs pour avoir les **mêmes** performances,
→ réduction fréquence par deux
(et donc réduction tension d'alimentation, consommation).

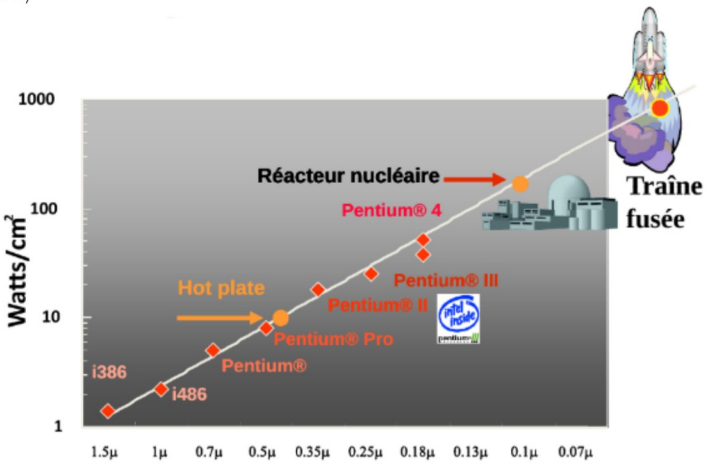
A performances données, la puissance **diminue** *quadratiquement* avec le parallélisme.

L'utilisation de processeurs parallèles permet également de lutter contre le mur du parallélisme d'instruction (***ILP wall***).

Présent dans la totalité des architectures actuelles.

Les *murs* de l'architecture : *Power wall* (cont.)

Forte augmentation de la densité de puissance par unité de surface
Problème majeur (évacuation de la chaleur, possibilité de destruction des transistors)



Grandes tendances architecturales

- Multicoeurs (parallélisme symétrique).
  Quasi généralisé dans les processeurs pour PC et les systèmes embarqués
- Parallélisme au sein des processeurs : parallélisme d'instruction, parallélisme SIMD (traitement parallèle de données)
- Utilisation de processeurs graphiques à parallélisme massif pour le calcul (GP-GPU)
- Systèmes hétérogènes. Réunion sur un même circuit de processeurs, GPU, systèmes parallèles spécialisés, DSP, etc.
- Intégration de processeurs et de matériel programmable (FPGA)

Welcome to the parallel jungle! (Herb SUTTER 2012)

Les *murs* de l'architecture : *Power wall* (cont.)

Historique CPU Intel

A terme la dissipation risque d'être le facteur limitant de l'intégration; « *dark silicon*[8] »

Fin de la loi de Dennard vers 2006
Fort ralentissement de la loi de Koomey (*la quantité de calcul par Joule double tous les deux ans*)

$\Longrightarrow$ Forte augmentation de la puissance à dissiper.

Possibilité d'intégrer un grand nombre de processeurs par circuits,
mais on ne pourra en activer qu'une partie pour limiter la dissipation thermique

Pourrait atteindre $\approx$ 80% en 3nm.
Très forte limite des performances.
Peut pousser à l'utilisation de processeurs très spécialisés...

[8] *Dark Silicon and the End of Multicore Scaling*, Hadi ESMAEILZADEH et *al.*, ISCA 2011

Grandes tendances architecturales (cont.)

La difficulté essentielle dans le parallélisme est son exploitation efficace.

Loi d'Amdahl (Gene AMDAHL 1922–2015)

Soit un programme ayant un temps d'exécution $t = t_s + t_a$

$t_s = t(1-\tau)$ temps intrinsèquement séquentiel (non parallélisable)
$t_a = t\tau$ temps de la partie du programme accélérable (parallélisable)
τ fraction parallélisable

Si on accélère t_a par un facteur $A > 1$, l'accélération finale est:

$$A' = \frac{t}{t'} = \frac{t_s + t_a}{t_s + \frac{t_a}{A}}$$

$$A' = A \times \frac{1}{\tau + A(1-\tau)}$$

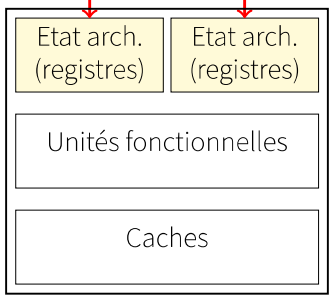
Exemple : Si on accélère par $A = 10$ une fraction $\tau = 0.5$ d'un programme, le gain final est de $A' = \frac{1}{0.5+0.05} = 1.82$

Grandes tendances architecturales (cont.)
multithreading

multithreads et multiprocesseurs

Processeur *multithread*

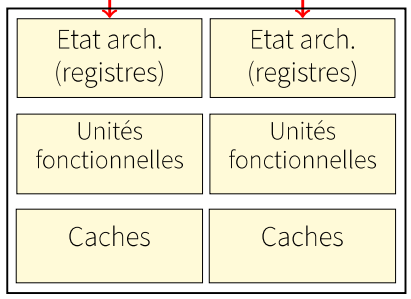
proc. log. 1 proc. log. 2



Mémoire principale

Processeur multicoeurs

proc. phys. 1 proc. phys. 2



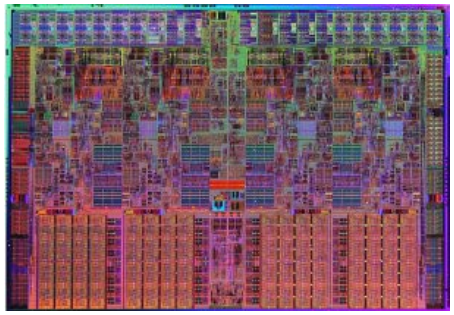
Mémoire principale

2 proc. logiques / proc. physique

Grandes tendances architecturales (cont.)
parallélisme

Parallélisme dans les processeurs pour PC.

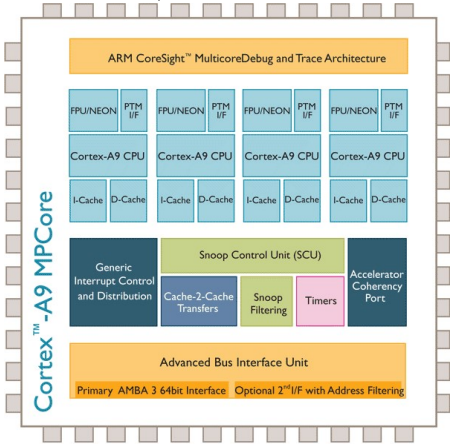
- *hyperthreading*
- multicoeurs/*manycores*



Processeur core i7 d'intel (4 coeurs).

Grandes tendances architecturales (cont.)
multicoeurs

Parallélisme en systèmes embarqués



Mais le parallélisme peut être beaucoup plus important.
MPPA Kalray 256 processeurs.

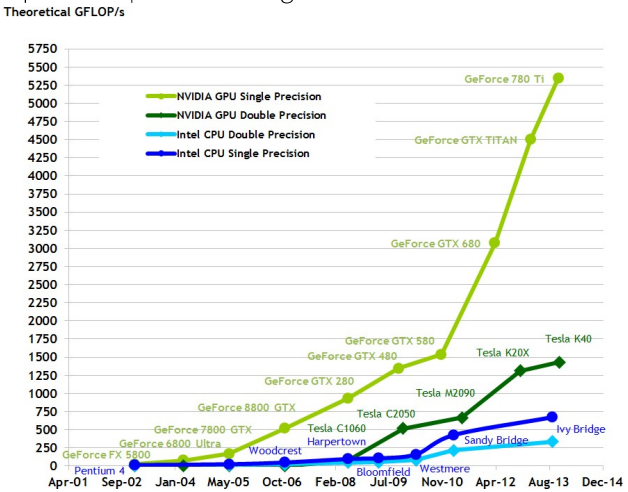
Le spectre d'implémentation

ASIC	Processeur	Reconfigurable
Circuit intégré dédié à une application	Utilisation de processeurs généraux	FPGA
Hautes performances	Programmable	Bon compromis
Consommation réduite	Flexible	Permet de mélanger sur un circuit
Long et couteux à développer	Non optimisé pour une application	matériel et processeurs

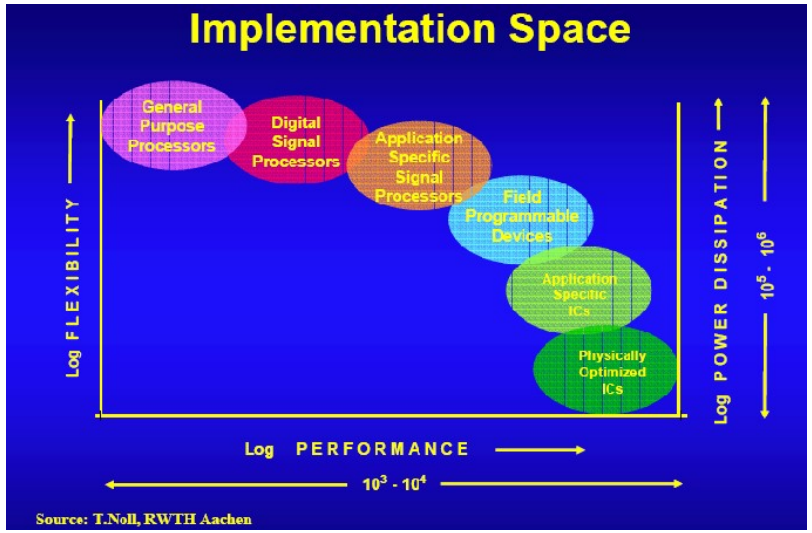
Grandes tendances architecturales (cont.)

GPU

Les processeurs graphiques (GPU) donnent une puissance de calcul considérable pour des problèmes réguliers.

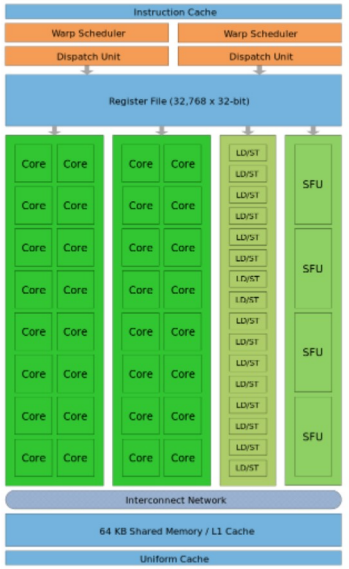


Le spectre d'implémentation (cont.)



Grandes tendances architecturales (cont.)

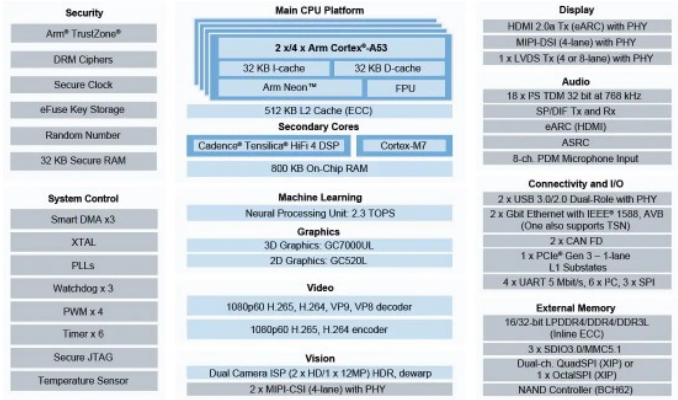
GPU



Microarchitecture de la série Fermi de NVidia

Existent en version embarquée avec une faible consommation (≈ 10W) (Tegra).
Ces versions intégrent des processeurs *arm* et un GPU de taille réduite (256-512 coeurs)

Le spectre d'implémentation (cont.)
systèmes hétérogènes

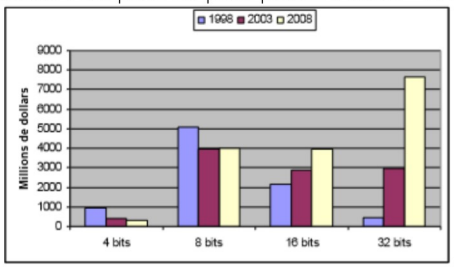


IMX8M+ de freescale (nxp)

- 4 ARM Cortex A-53
- 1 ARM Cortex M7
- Processeur neuronal NPU 2.3TOPS
- GPU 16GFLOPS
- 2 processeurs d'images 375MPixels/s
- 4 DSP Tensilica HiFi

Le spectre d'implémentation (cont.)
microcontrôleurs

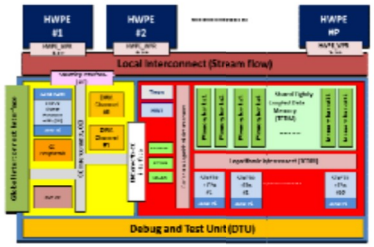
Microcontroleurs
Intègrent des processeurs de plus en plus performants + RAM/ROM + E/S

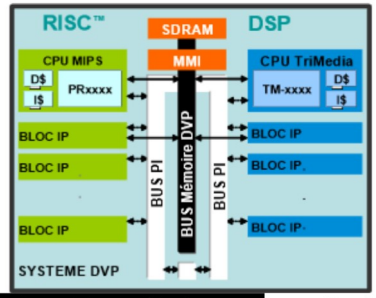


Le spectre d'implémentation (cont.)
systèmes hétérogènes

systems on chip intégrant des opérateurs matériels spécifiques

La "plateforme 2012" de ST-micro

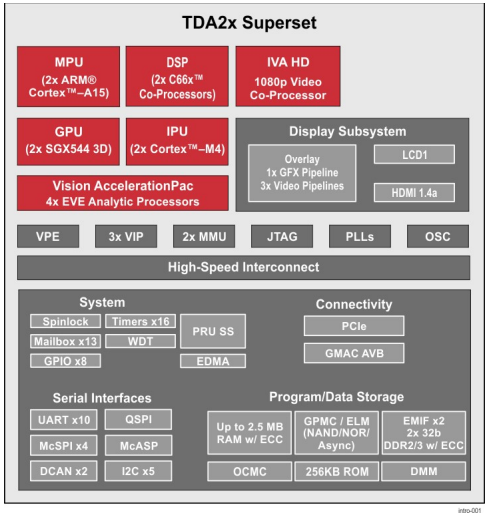




Le système nexperia (Phillips)

Le spectre d'implémentation (cont.)
systèmes hétérogènes

systems on chip hétérogènes

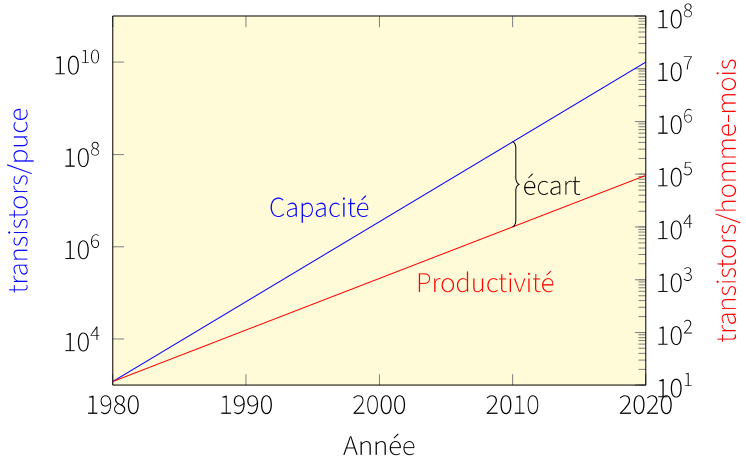


TDA2X (TI)
Circuit dédié aux applications « véhicules intelligents »

- 2×ARM Cortex-A15 + 2× ARM Cortex-M4
- 2×DSP C66x
- 2×GPU
- 4×accélérateurs pour traitement d'images

Productivity-Design gap

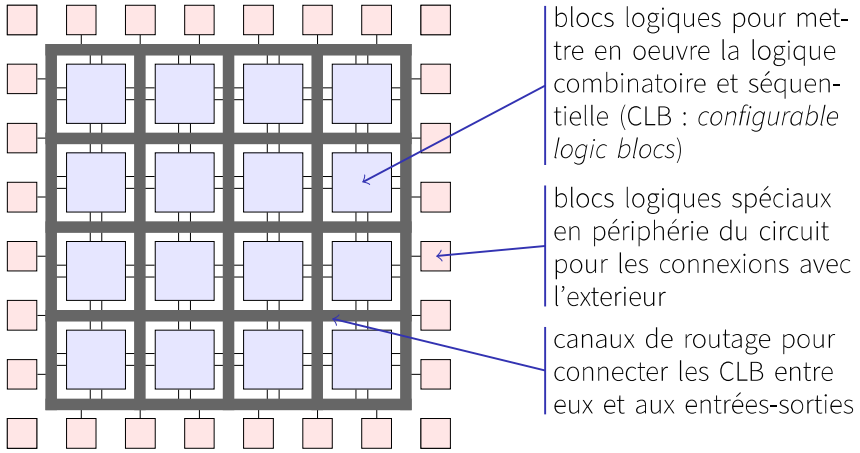
La capacité potentielle des circuits croit plus vite que la productivité des concepteurs



Le spectre d'implémentation (cont.)

FPGA

Les circuits programmables FPGA (xilinx, altera, lattice, ...)



Etat de l'art (2019)

Transistors $\times 10^9$		
CPU : AMD Epyc Rome 64 coeurs	32	7 nm
GPU : NVidia A100 (Ampere) (6912 CUDA Cores)	54	7nm
FPGA : Xilinx Virtex ultrascale+	35	16nm
Mémoire (DDR5) : 512Gb	600	10nm

Performances crête maximales théoriques (TFlops)	
CPU (*skylake*) (DP avec AVX-512 et 2×FMA) (/coeur)	0.1
CPU Arm Cortex A72 (DP avec Neon) (/coeur)	0.006
GPU (7000 SM) (DP)	18
avec *tensor cores* (SP) (Volta, Turing, Ampere)	150
FPGA (SP)	20

Débit mémoire maximum (Go/s)	
CPU	100
GPU	600

Le spectre d'implémentation (cont.)

FPGA

Les famille de FPGA les plus récentes (Virtex (Xilinx), Stratix (Altera/Intel)):

- intégrent des blocs logiques programmables sophistiqués
- comprennent des blocs de mémoire (jusqu'à 500Mo)
- ont des possibilités de calcul élevées (blocs DSP multiplieur-accumulateurs flottants).
  Puissance de calcul crête ≈ 10–20 Tflops
- mise en oeuvre avec des langages de haut niveau (open-CL)

Il peuvent :

- mettre en oeuvre des processeurs *softcore* personnalisables (*customisables*) (nios, microblaze).
- intégrer un ou plusieurs processeurs *hardcore* (Arm)

Les règles d'or de l'architecture

- Prendre en compte la technologie
- Accélérer le cas le plus fréquent
- Utiliser le parallélisme
- Utiliser le pipeline
- Utiliser la prédiction
- Hiérarchiser la mémoire

Plan du cours

Jeux d'instructions

Processeurs pipeline, dépendances, réordonnancement, prédiction de branchement

Parallélisme d'instructions : processeurs superscalaires et VLIW

Hiérarchie mémoire, caches, mémoire virtuelle

Optimisations logicielles